



TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH

BỘ MÔN CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN TỐT NGHIỆP

ĐỀ TÀI

XÂY DỰNG HỆ THỐNG NHẬN DIỆN VÀ PHÂN LOẠI BIỂN BÁO
GIAO THÔNG VIỆT NAM SỬ DỤNG DEEP LEARNING

Sinh viên thực hiện : Phan Đức An

Mã sinh viên : 6351071001

Khoá : CQ.63.CNTT



TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN TỐT NGHIỆP

ĐỀ TÀI: XÂY DỰNG HỆ THỐNG NHẬN ĐIỆN VÀ PHÂN LOẠI
BIỂN BÁO GIAO THÔNG VIỆT NAM SỬ DỤNG DEEP
LEARNING

Giảng viên hướng dẫn: ThS. TRẦN PHONG NHÃ

Sinh viên thực hiện: PHAN ĐỨC AN

Lớp : CQ.63.CNTT

Khoá : K63

Tp. Hồ Chí Minh, năm 2026

NHIỆM VỤ THIẾT KẾ ĐỒ ÁN TỐT NGHIỆP

BỘ MÔN: CÔNG NGHỆ THÔNG TIN

----- *** -----

Mã sinh viên: 6351071001

Họ tên SV: Phan Đức An

Khóa: 63

Lớp: CQ.63.CNTT

1. Tên đề tài

Xây dựng hệ thống nhận diện và phân loại biển báo giao thông Việt Nam sử dụng deep learning

2. Mục đích thực hiện

- Nghiên cứu và ứng dụng các kỹ thuật Deep Learning trong bài toán nhận diện và phân loại biển báo giao thông.
- Xây dựng một hệ thống có khả năng phát hiện và nhận dạng tự động các biển báo giao thông Việt Nam từ ảnh và video.
- Đánh giá hiệu quả của các mô hình học sâu, góp phần hỗ trợ phát triển các hệ thống giao thông thông minh và phương tiện tự hành.

3. Mục tiêu thực hiện

- Xây dựng mô hình phát hiện vị trí biển báo giao thông trong ảnh bằng thuật toán YOLO.
- Xây dựng mô hình phân loại biển báo giao thông bằng mạng nơ-ron tích chập (CNN).
- Đánh giá và so sánh hiệu quả của các mô hình được đề xuất.
- Xây dựng ứng dụng web hỗ trợ nhận diện biển báo trên ảnh và video.

4. Nội dung và phạm vi đề tài

Đề tài tập trung giải quyết bài toán nhận diện và phân loại biển báo giao thông Việt Nam từ dữ liệu ảnh và video.

- Đầu vào: Ảnh hoặc video chứa biển báo giao thông.
- Đầu ra: Vị trí biển báo được phát hiện và nhãn phân loại tương ứng.

Các nội dung thực hiện:

- Nghiên cứu cơ sở lý thuyết về Deep Learning, CNN và YOLO.
- Xây dựng và tiền xử lý bộ dữ liệu.
- Huấn luyện, đánh giá và so sánh các mô hình YOLOv5n, YOLOv8n và YOLOv11n cho bài toán phát hiện biển báo.
- Huấn luyện mô hình CNN cho bài toán phân loại biển báo.
- Xây dựng hệ thống web tích hợp chức năng nhận diện trên ảnh và video.

Phạm vi đề tài giới hạn ở các loại biển báo giao thông Việt Nam có trong bộ dữ liệu nghiên cứu.

5. Phương pháp thực hiện

- Ngôn ngữ lập trình: Python.
- Framework Deep Learning: PyTorch.
- Mô hình phát hiện đối tượng: YOLOv5n, YOLOv8n, YOLOv11n.
- Mô hình phân loại ảnh: CNN.
- Thư viện xử lý ảnh: OpenCV.
- Framework xây dựng giao diện web: Streamlit.
- Công cụ huấn luyện và đánh giá mô hình: Ultralytics YOLO, Scikit-learn.
- Phương pháp đánh giá: Precision, Recall, F1-score, mAP và Accuracy.

6. Các kết quả chính dự kiến sẽ đạt được

- Xây dựng được bộ dữ liệu biển báo giao thông Việt Nam phục vụ nghiên cứu.
- Huấn luyện thành công các mô hình phát hiện và phân loại biển báo giao thông.
- Xác định được mô hình có hiệu quả tốt nhất thông qua các chỉ số đánh giá.

- Xây dựng hoàn chỉnh hệ thống web nhận diện biển báo giao thông trên ảnh và video.
- Hoàn thành báo cáo đồ án tốt nghiệp và các tài liệu liên quan.

7. Kế hoạch thực hiện

- Giai đoạn 1: Khảo sát tài liệu, nghiên cứu cơ sở lý thuyết.
- Giai đoạn 2: Thu thập và xây dựng bộ dữ liệu.
- Giai đoạn 3: Huấn luyện và đánh giá các mô hình YOLO.
- Giai đoạn 4: Huấn luyện và đánh giá mô hình CNN.
- Giai đoạn 5: Xây dựng ứng dụng web và tích hợp hệ thống.
- Giai đoạn 6: Kiểm thử, hoàn thiện hệ thống và viết báo cáo.

8. Giáo viên và cán bộ hướng dẫn

Họ tên: ThS. Trần Phong Nhã

Đơn vị công tác: Bộ môn Công nghệ Thông tin, Trường Đại học Giao thông Vận tải –
Phân hiệu TP.HCM

Điện thoại: 0906761014

Email: tpnha@utc2.edu.vn

Ngày 02 tháng 03 năm 2026
Trưởng BM Công nghệ Thông tin

Đã giao nhiệm vụ TKTN
Giảng viên hướng dẫn

ThS. Trần Phong Nhã

ThS. Trần Phong Nhã

Đã nhận nhiệm vụ TKTN

Sinh viên: Phan Đức An

Điện thoại: 0343811543

Ký tên:

Email: 6351071001@st.utc2.edu.vn

LỜI CẢM ƠN

Em xin gửi lời cảm ơn sâu sắc đến các thầy cô trong Bộ môn Công nghệ Thông tin Phân hiệu Trường Đại học Giao thông Vận tải Thành phố Hồ Chí Minh cũng như các thầy cô thỉnh giảng từ các trường bên ngoài. Trong các năm học vừa qua, thầy cô đã giúp đỡ em rất nhiều trong quá trình học tập và phát triển bản thân. Nhờ những kiến thức của thầy cô mà em mới có thể có được ngày hôm nay, được tốt nghiệp cùng bạn bè và đi trên con đường mới.

Em cảm ơn thầy Trần Phong Nhã vì đã gắn bó và đồng hành cùng em trong suốt những năm học vừa qua, những bài giảng của thầy rất bổ ích và cho em nhiều kiến thức quan trọng. Em cảm ơn thầy vì đã chỉ dẫn em nhiệt tình cho đề án tốt nghiệp năm nay, nhờ thầy mà em có được định hướng cụ thể để có thể hoàn thành đề án một cách trọn vẹn và hiệu quả.

Em xin chúc các thầy cô luôn mạnh khỏe và luôn thành công trong những năm học kế tiếp, em chân thành cảm ơn thầy cô.

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Tp. Hồ Chí Minh, ngày ... tháng ... năm 2026

Giảng viên hướng dẫn

Ths. Trần Phong Nhã

MỤC LỤC

NHIỆM VỤ THIẾT KẾ ĐỒ ÁN TỐT NGHIỆP.....	i
LỜI CẢM ƠN.....	iv
NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN.....	v
MỤC LỤC	vi
DANH MỤC HÌNH ẢNH.....	ix
DANH MỤC BẢNG BIỂU	xi
DANH MỤC CHỮ VIẾT TẮT	xii
TỔNG QUAN.....	1
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT.....	3
1.1 Convolutional Neural Network.....	3
1.1.1 Khái niệm Convolutional Neural Network	3
1.1.2 Cấu trúc cơ bản của CNN	3
1.1.3 Cơ chế học đặc trưng của CNN	4
1.1.4 Ứng dụng của CNN trong nhận diện biển báo giao thông.....	5
1.2 Object Detection	6
1.2.1 Khái niệm Object Detection.....	6
1.2.2 Các thành phần của bài toán Object Detection	6
1.2.3 Các hướng tiếp cận trong Object Detection.....	7
1.2.4 Vai trò của Object Detection trong nhận diện biển báo giao thông	8
1.3 YOLO.....	9
1.3.1 Tổng quan về YOLO	9
1.3.2 Nguyên lý hoạt động của YOLO	9
1.3.3 Ưu điểm và hạn chế của YOLO	10
1.4.5 Vai trò của YOLO trong bài toán nhận diện biển báo giao thông.....	11
1.4 ResNet và EfficientNet	11

1.4.1 Tổng quan về các mô hình CNN hiện đại	11
1.4.2 ResNet	12
1.4.3 EfficientNet	13
1.4.4 So sánh ResNet và EfficientNet	14
1.4.5 Vai trò của ResNet và EfficientNet trong đề tài	14
1.5 Chỉ số đánh giá mô hình	14
1.5.1 Precision	15
1.5.2 Recall	15
1.5.3 F1-score	16
1.5.4 Accuracy	16
1.5.5 IoU	16
1.5.6 mAP	17
1.5.7 Confusion Matrix	17
1.5.8 Tốc độ suy luận	17
CHƯƠNG 2: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG	19
2.1 Dữ liệu nghiên cứu	19
2.1.1. Tổng quan	19
2.1.2 Thống kê bộ dữ liệu	19
2.2 Quy trình xử lý dữ liệu	22
2.2.1 Chuẩn hóa dữ liệu cho YOLO	22
2.2.2 Xây dựng tập dữ liệu Classification cho CNN	23
2.3 Thiết kế hệ thống	25
2.3.1 Kiến trúc tổng thể hệ thống	25
2.3.2 Luồng kiểm thử YOLO End-to-End	26
2.3.3. Luồng kiểm thử YOLO kết hợp CNN	27
2.4 Xây dựng mô hình YOLO	28
2.4.1 Các mô hình YOLO sử dụng	28
2.4.2 Data Augmentation trong huấn luyện YOLO	29
2.4.3 Cấu hình huấn luyện YOLO	30

2.5 Xây dựng mô hình CNN	32
2.5.1 ResNet50	32
2.5.2 EfficientNet-B0	33
2.5.3 Cấu hình huấn luyện.....	33
CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ	36
3.1 Môi trường và kịch bản thực nghiệm	36
3.2 Kết quả thực nghiệm YOLO	37
3.2.2 Phân tích ảnh hưởng Hyperparameter.....	39
3.2.3 Lựa chọn mô hình YOLO tốt nhất	41
3.3 Kết quả thực nghiệm CNN	43
3.3.1 Đánh giá baseline ResNet50 và EfficientNet-B0.....	43
3.3.2 Phân tích Hyperparameter.....	44
3.3.3 Lựa chọn mô hình CNN tốt nhất.....	46
3.4 Đánh giá các hướng tiếp cận.....	46
3.4.1 Phương pháp đánh giá.....	46
3.4.2 Kết quả đánh giá.....	46
3.4.3 So sánh và thảo luận.....	48
3.5 Triển khai hệ thống Web	49
3.5.1 Kiến trúc hệ thống.....	49
3.5.2. Giao diện người dùng.....	51
KẾT LUẬN VÀ KIẾN NGHỊ	55
1. Kết quả đạt được.....	55
2. Hạn chế.....	56
3. Hướng phát triển.....	56
PHỤ LỤC	58
TÀI LIỆU THAM KHẢO	60

DANH MỤC HÌNH ẢNH

Hình 1.1 Kiến trúc cơ bản của mạng CNN	3
Hình 1.2 Minh họa quá trình tích chập.....	4
Hình 1.3 Cơ chế học đặc trưng phân cấp	5
Hình 1.4 Cấu tạo của Object Detection	7
Hình 1.5 So sánh hai hướng tiếp cận.....	8
Hình 1.6 Nguyên lý hoạt động của YOLO	10
Hình 1.7 Kiến trúc mạng ResNet	12
Hình 1.8 Kiến trúc EfficientNet	13
Hình 2.1 Trung bình biên báo mỗi ảnh.....	20
Hình 2.2 15 lớp có số mẫu nhiều nhất.....	21
Hình 2.3 15 lớp có số mẫu ít nhất.....	21
Hình 2.4 Quy trình chuẩn hóa dữ liệu	22
Hình 2.5 Xây dựng dữ liệu cho CNN	24
Hình 2.6 Cấu trúc 2 luồng kiểm thử	26
Hình 2.7 Luồng kiểm thử YOLO End-to-End.....	26
Hình 2.8 Kiểm thử YOLO kết hợp CNN	28
Hình 2.9 Kỹ thuật Mosaic	29
Hình 2.10 Luồng đánh giá YOLO	31
Hình 2.11 Luồng đánh giá CNN.....	34
Hình 3.1 Luồng đánh giá tổng thể.....	36
Hình 3.2 Kết quả baseline của YOLO	38

Hình 3.3 kết quả ảnh hưởng của imgsize	39
Hình 3.4 Kết quả ảnh hưởng của learning.....	40
Hình 3.5 Kết quả ảnh hưởng batchsize.....	41
Hình 3.6 Kết quả so với baseline.....	42
Hình 3.7 Kết quả baseline của CNN	43
Hình 3.8 Kết quả ảnh hưởng của learning.....	44
Hình 3.9 Ảnh hưởng của transfer learning	45
Hình 3.10 Kết quả đánh giá luồng CNN	47
Hình 3.11 Giao diện tính năng nhận diện.....	52
Hình 3.12 Giao diện nhận diện ảnh tĩnh.....	52
Hình 3.13 Giao diện tính năng nhận diện.....	53
Hình 3.14 Kết quả nhận diện trên video.....	53

DANH MỤC BẢNG BIỂU

Bảng 2.1 Tỷ lệ chia dữ liệu	20
Bảng 2.2 Đối tượng khảo sát của YOLO	31
Bảng 2.3 Đối tượng khảo sát của CNN	35
Bảng 3.1 Các thành phần của hệ thống	49
Bảng 3.2 Các API chính của hệ thống	50

DANH MỤC CHỮ VIẾT TẮT

STT	Viết tắt	Giải thích
1	ADAS	Advanced Driver Assistance Systems (Hệ thống hỗ trợ lái xe nâng cao)
2	AP	Average Precision (Độ chính xác trung bình)
3	API	Application Programming Interface (Giao diện lập trình ứng dụng)
4	CNN	Convolutional Neural Network (Mạng nơ-ron tích chập)
5	CVPR	Conference on Computer Vision and Pattern Recognition (Hội nghị IEEE về Thị giác máy tính và Nhận dạng mẫu)
6	Deep Learning	Học sâu
7	ECCV	European Conference on Computer Vision (Hội nghị châu Âu về Thị giác máy tính)
8	EfficientNet	Efficient Neural Network (Họ mô hình CNN tối ưu hóa hiệu quả tính toán)
9	F1-score	F1 Score (Điểm F1)
10	FN	False Negative (Âm tính giả)
11	FP	False Positive (Dương tính giả)
12	FPS	Frames Per Second (Số khung hình xử lý mỗi giây)
13	GET	HTTP GET Method (Phương thức GET trong HTTP)
14	ICML	International Conference on Machine Learning (Hội nghị Quốc tế về Học máy)

STT	Viết tắt	Giải thích
15	ICCV	International Conference on Computer Vision (Hội nghị Quốc tế về Thị giác máy tính)
16	ImageNet	ImageNet Dataset (Bộ dữ liệu ImageNet)
17	IoU	Intersection over Union (Chỉ số giao trên hợp)
18	JPG	Joint Photographic Experts Group (Định dạng ảnh JPG/JPEG)
19	mAP	Mean Average Precision (Độ chính xác trung bình)
20	MBConv	Mobile Inverted Bottleneck Convolution
21	NMS	Non-Maximum Suppression (Thuật toán loại bỏ cực đại không tối đa)
22	POST	HTTP POST Method (Phương thức POST trong HTTP)
23	PyTorch	Python Torch (Framework học sâu PyTorch)
24	ReLU	Rectified Linear Unit
25	REST	Representational State Transfer
26	ROC	Receiver Operating Characteristic
27	SSD	Single Shot MultiBox Detector
28	TP	True Positive (Dương tính thật)
29	TN	True Negative (Âm tính thật)
30	Transfer Learning	Học chuyển giao

STT	Viết tắt	Giải thích
31	VOC	Visual Object Classes
32	YOLO	You Only Look Once

TỔNG QUAN

1. Tình hình nghiên cứu

Tại Việt Nam, đa số cá nghiên cứu hiện nay phần lớn tập trung vào việc sử dụng một mô hình duy nhất để vừa thực hiện phát hiện và phân loại đối tượng. Mặc dù cách tiếp cận này giúp đơn giản kiến trúc hệ thống và giảm thời gian suy luận, khả năng phân biệt giữa các lớp biến báo giống nhau vẫn còn điểm hạn chế. Do đó xu houwngs kết hợp giữa mô hình phát hiện đối tượng và phân loại chuyên biệt đang được quan tâm mục đích nhằm khai thác ưu điểm của từng đối tượng trong kiến trúc hệ thống.

2. Lý do chọn đề tài

Đề tài “Xây dựng hệ thống nhận diện và phân loại biến báo giao thông Việt Nam sử dụng Deep Learning” được lựa chọn nhằm nghiên cứu, xây dựng và đánh giá các phương pháp nhận diện biến báo phù hợp với điều kiện dữ liệu và nhu cầu ứng dụng thực tế tại Việt Nam. Nội dung đề tài phù hợp với định hướng phát triển của lĩnh vực thị giác máy tính, đồng thời có khả năng mở rộng cho các hệ thống giao thông thông minh trong tương lai.

3. Mục tiêu của đề tài

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống có khả năng phát hiện và phân loại biến báo giao thông Việt Nam dựa trên các kỹ thuật Deep Learning, đồng thời đánh giá hiệu quả của các hướng tiếp cận khác nhau đối với bài toán này.

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là các phương pháp và mô hình Deep Learning được sử dụng trong bài toán nhận diện biến báo giao thông Việt Nam. Trọng tâm nghiên cứu tập trung vào các kỹ thuật phát hiện đối tượng và phân loại ảnh nhằm xây dựng hệ thống có khả năng xác định vị trí cũng như nhận dạng chính xác các loại biến báo xuất hiện trong ảnh hoặc video.

Bên cạnh các mô hình học sâu, đề tài cũng nghiên cứu quy trình xây dựng dữ liệu, kỹ thuật tiền xử lý ảnh, phương pháp đánh giá mô hình và các yếu tố ảnh hưởng đến hiệu năng của hệ thống nhận diện biển báo giao thông.

Đề tài tập trung xây dựng hệ thống nhận diện và phân loại 52 lớp biển báo giao thông Việt Nam trên dữ liệu ảnh. Hệ thống được phát triển bằng ngôn ngữ Python, sử dụng thư viện PyTorch và framework Ultralytics để triển khai các mô hình học sâu.

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1 Convolutional Neural Network


1.1.1 Khái niệm Convolutional Neural Network

CNN là một kiến trúc mạng nơ-ron được thiết kế cho việc xử lý dữ liệu dạng lưới, chủ yếu là dạng ảnh. Khác với các mạng nơ-ron bình thường, CNN có thể khai thác mối quan hệ trong mặt phẳng giữa các điểm ảnh thông qua phép tích chập, và từ đó có thể học được các đặc trưng từ dữ liệu đầu vào [3].

Đối với dữ liệu ảnh, CNN có thể học các đặc trưng cơ bản như cạnh, góc, đường cong... từ tầng đầu tiên, sau đó sẽ hình thành các đặc trưng rõ hơn ở tầng kết tiếp. Điều này cho phép mô hình nhận diện tốt hơn các đối tượng phức tạp [3].


1.1.2 Cấu trúc cơ bản của CNN

Mô hình CNN thường được cấu tạo từ nhiều tầng khác nhau, trong đó thành phần chính bao gồm tầng tích chập, tầng gộp và tầng kết nối đầy đủ.



Hình 1.1 Kiến trúc cơ bản của mạng CNN

Tầng tích chập có vai trò là trích xuất đặc trưng từ ảnh đầu vào. Mỗi vị trí có bộ lọc trượt đều trên ảnh để trích xuất và tạo ra các vector đặc trưng. Mỗi bộ lọc có nhiệm vụ trích xuất một đặc trưng, ví dụ như chiều cao, chiều sâu [3].



Hình 1.2 Minh họa quá trình tích chập


Sau khi tích chập, hàm ReLU được sử dụng để làm tăng khả năng biểu diễn của mạng, từ đó tăng tốc độ học trong quá trình huấn luyện [6].

Tầng gộp có chức năng giảm kích thước của các đặc trưng đã trích xuất. Điều này giúp giảm khối lượng tham số mà mô hình cần học, giúp làm tăng tính tổng quát của mô hình lên. Trong nhiều bài toán, Max Pooling là phương pháp phổ biến có thể giữ lại các đặc trưng nổi bật trong quá trình học [3].

Cuối cùng, tầng kết nối đầy đủ sẽ tiếp nhận các đặc trưng để thực hiện quá trình phân loại. Đầu ra sẽ là danh sách các xác suất của các lớp, xác suất lớn nhất sẽ được chọn.

1.1.3 Cơ chế học đặc trưng của CNN

CNN có khả năng học đặc trưng theo kiểu phân cấp. Nghĩa là thay vì xử lý toàn bộ ảnh, mô hình sẽ ứng dụng tính chất cục bộ của ảnh để làm tăng khả năng học.



Hình 1.3 Cơ chế học đặc trưng phân cấp

Kết nối thưa là dạng kết nối cho phép mỗi điểm chỉ có thể tương tác với một vùng, điều này sẽ giúp làm giảm đáng kể số lượng tham số, từ đó giúp mô hình dự đoán tốt hơn [3].

Cơ chế chia sẻ trọng số cho phép một bộ lọc sẽ được áp dụng lên toàn bộ ảnh. Và nhờ vậy CNN có thể phát hiện nhiều đặc trưng ở các nơi cùng lúc, đây chính là yếu tố quan trọng nhất khiến CNN nổi bật cho vai trò nhận diện ảnh [5].

Tỉ lệ thuận với số lượng của tầng, mô hình CNN sẽ học được nhiều cách biểu diễn hơn. Những tầng ban đầu sẽ nhận các đặc trưng cơ bản, trong khi những tầng cuối học được các đặc trưng phức tạp hơn. Trong bài toán nhận diện biển báo, điều này rất nổi bật trong tính chính xác.

1.1.4 Ứng dụng của CNN trong nhận diện biển báo giao thông

CNN thường được tận dụng nhờ khả năng phát hiện mạnh mẽ, ảnh của biển báo sẽ được cắt ra và đưa vào mạng CNN này để thực hiện phân loại, từ đó nâng cao khả năng nhận diện nhờ khả năng tập trung và không bị phân tán bởi môi trường xung quanh.

1.2 Object Detection

1.2.1 Khái niệm Object Detection

Object Detection là định nghĩa về xác định vị trí và phân lớp các đối tượng. Nó khác với Image Classification, thứ chỉ đưa ra nhãn của ảnh, thì Object Detection có thể xác định được cả vị trí của ảnh và biết ảnh thuộc lớp nào [1].

Đầu ra của Object Detection bao gồm các khung bounding box, nhãn và xác suất của lớp. Mỗi khung bounding sẽ được gán chính xác với đối tượng, nhãn cũng được gán cho đối tượng.

1.2.2 Các thành phần của bài toán Object Detection

Hệ thống phát hiện đối tượng bao gồm ba tính năng chính: trích xuất đặc trưng, xác định vị trí và phân loại đối tượng.

Bước đầu tiên là trích xuất đặc trưng của đối tượng. Các mạng CNN được dùng để trích xuất các đặc trưng từ ảnh. Những đặc trưng này đóng vai trò rất quan trọng cho những bước xử lý tiếp theo [7]

Tiếp theo là nhiệm vụ định vị đối tượng (Localization). Mục tiêu của giai đoạn này là xác định vị trí xuất hiện của đối tượng thông qua các bounding box. Độ chính xác của bounding box ảnh hưởng trực tiếp đến hiệu quả của toàn bộ hệ thống phát hiện.

Bước cuối cùng, hệ thống sẽ phân loại đối tượng bằng cách dự đoán lớp cho vùng tương ứng được phát hiện. Kết quả đầu ra sẽ gồm xác suất của từng lớp và confidence để cho biết độ tin cậy.




Hình 1.4 Cấu tạo của Object Detection

Khi đang trong quá trình suy luận, một đối tượng có thể có nhiều khung bounding. Để loại bỏ các khung dư thừa này, kỹ thuật NMS sẽ được sử dụng để giữ lại các dự đoán có xác suất cao và loại bỏ các khung thừa chồng lấn [1].

1.2.3 Các hướng tiếp cận trong Object Detection

Các phương pháp phát hiện đối tượng hiện nay được chia làm hai nhóm chính là two-stage detector và single-stage detector. Mỗi nhóm này có một đặc trưng khác nhau, làm nổi bật sự đa dạng trong khả năng phát hiện.

Đối với nhóm two-stage detector, nhóm này thực hiện quá trình phát hiện đối tượng qua hai bước. Đầu tiên, hệ thống sinh ra các vùng ứng viên tiềm năng chứa đối tượng. Tiếp đó sẽ dự đoán từng vùng và tạo khung bounding box. Các mô hình sử dụng kiểu này bao gồm Fast R-CNN và Faster R-CNN [8].



Hình 1.5 So sánh hai hướng tiếp cận

Mô hình hai giai đoạn có ưu điểm lớn là có độ chính xác cao nhờ quá trình xử lý chi tiết ở từng vùng dự đoán. Nhưng việc thực hiện nhiều bước liên tiếp nhau có thể dẫn đến chi phí dự đoán và giảm rất nhiều tốc độ suy đoán, do đó về mặt thời gian thực, mô hình này không được tốt.

Khác với nhóm hai giai đoạn, nhóm single-stage detector có ưu điểm không cần vùng ứng viên, mà thực hiện suy đoán trên một lần duy nhất. Do đó có ưu điểm về mặt thời gian thực, YOLO chính là đại diện tiêu biểu cho nhóm này [10].

Với kiến trúc đơn giản hơn, các mô hình single-stage đạt tốc độ xử lý cao hơn đáng kể so với các phương pháp hai giai đoạn. Điều này rất quan trọng đối với các hệ thống cần phản hồi nhanh như camera giao thông, phương tiện tự hành hoặc các ứng dụng giám sát trong thời gian thực.

1.2.4 Vai trò của Object Detection trong nhận diện biển báo giao thông

Trong hệ thống nhận diện biển báo giao thông, khả năng nhận diện đối tượng có vai trò cực quan trọng, đó là nền tảng của toàn bộ hệ thống. Trước khi đến với bước phân

loại, hệ thống phải xác định đúng vị trí của biển báo, từ đó mới giúp hệ thống nhận diện được, nếu không thì sẽ rất khó khăn.

Có rất nhiều mô hình Object Detection hiện đại như YOLO, Faster R-CNN đã thành công trong việc áp dụng cho nhiều bài toán nhận diện [10]. Trong tất cả, YOLO được đánh giá rất cao nhờ vào khả năng cân bằng giữa tốc độ suy luận và độ chính xác.

1.3 YOLO

1.3.1 Tổng quan về YOLO

YOLO là họ mô hình phát hiện đối tượng thuộc nhóm single-stage detector, được giới thiệu lần đầu vào năm 2016 [10]. Khác với các phương pháp two-stage detector như Fast R-CNN hay Faster R-CNN, YOLO thực hiện cả nhiệm vụ định vị và phân loại đối tượng trong một lần suy luận duy nhất. Điều này giúp giảm rất nhiều độ phức tạp trong tính toán và gia tăng tốc độ xử lý, đặc biệt phù hợp với các ứng dụng yêu cầu phản hồi theo thời gian thực [7].


Ý tưởng chính nhất của YOLO là xem bài toán phát hiện đối tượng như một bài toán hồi quy trực tiếp từ ảnh đầu vào đến tọa độ bounding box và xác suất lớp. Thay vì tạo ra các vùng đề xuất rồi tiến hành phân loại riêng biệt, toàn bộ ảnh được đưa qua một mạng nơ-ron duy nhất để dự đoán trực tiếp các đối tượng xuất hiện trong ảnh [10].

Nhờ khả năng xử lý nhanh và kiến trúc đơn giản, YOLO đã trở thành một trong những hướng nghiên cứu phổ biến nhất trong lĩnh vực Object Detection. Qua nhiều thế hệ phát triển, họ mô hình YOLO liên tục được cải tiến nhằm nâng cao độ chính xác, khả năng phát hiện vật thể nhỏ và hiệu quả suy luận trên các thiết bị có tài nguyên hạn chế [12].

1.3.2 Nguyên lý hoạt động của YOLO

Trong kiến trúc YOLO, ảnh đầu vào được chia thành nhiều vùng không gian. Đối với mỗi vùng, mô hình dự đoán một tập các bounding box cùng với độ tin cậy và xác suất thuộc về các lớp đối tượng khác nhau [10].

Quá trình suy luận của YOLO có thể được mô tả qua ba bước chính. Đầu tiên ảnh được đưa vào mạng CNN để trích xuất đặc trưng. Các đặc trưng này sau đó được sử dụng để dự đoán vị trí bounding box và xác suất lớp tương ứng. Cuối cùng, kỹ thuật NMS được áp dụng nhằm loại bỏ các dự đoán chồng lấn và giữ lại những kết quả có độ tin cậy cao nhất [10].



Hình 1.6 Nguyên lý hoạt động của YOLO

Đối với mỗi đối tượng được phát hiện, mô hình thường trả về ba thành phần chính gồm tọa độ bounding box, xác suất lớp và giá trị confidence. Confidence phản ánh mức độ chắc chắn của mô hình về việc một đối tượng thực sự tồn tại bên trong bounding box được dự đoán. Những dự đoán có confidence thấp thường bị loại bỏ trong quá trình hậu xử lý nhằm giảm số lượng dự đoán sai.

Một trong những ưu điểm quan trọng của YOLO là khả năng khai thác thông tin toàn cục của ảnh. Do toàn bộ ảnh được xử lý đồng thời thay vì từng vùng riêng lẻ, mô hình có thể tận dụng ngữ cảnh xung quanh đối tượng để cải thiện khả năng nhận dạng [10].

1.3.3 Ưu điểm và hạn chế của YOLO

Ưu điểm nổi bật nhất của YOLO là tốc độ suy luận cao. Nhờ thực hiện đồng thời quá trình định vị và phân loại trong một mạng duy nhất, mô hình có thể xử lý ảnh hoặc

video với tốc độ đủ nhanh cho các hệ thống thời gian thực như camera giao thông, robot hoặc phương tiện tự hành [12].

Tuy vậy, YOLO vẫn có một số nhược điểm. Đối với các đối tượng rất nhỏ, YOLO sẽ rất kém trong việc xử lý hoặc các đối tượng tương đồng cao cũng vậy. Trong những trường hợp yêu cầu phát hiện tinh vi, mô hình YOLO tỏ ra rất kém, do đó cần một bộ phận phân loại tốt hơn. Ngoài ra, chất lượng ảnh cũng ảnh hưởng rất nhiều đối với hiệu năng xử lý của YOLO [13].

1.4.5 Vai trò của YOLO trong bài toán nhận diện biển báo giao thông

YOLO được sử dụng rộng rãi trong các hệ thống nhận diện biển báo giao thông nhờ khả năng phát hiện nhanh các đối tượng có kích thước nhỏ trong môi trường phức tạp. Trong điều kiện thực tế, biển báo thường xuất hiện ở khoảng cách xa, chịu ảnh hưởng của ánh sáng, thời tiết hoặc hiện tượng che khuất. Những yếu tố này đòi hỏi mô hình phải vừa đảm bảo độ chính xác vừa duy trì tốc độ xử lý đủ cao để đáp ứng yêu cầu thời gian thực.

1.4 ResNet và EfficientNet

1.4.1 Tổng quan về các mô hình CNN hiện đại


Việc gia tăng độ sâu của mạng CNN đóng góp rất nhiều vào khả năng cải thiện học đặc trưng và độ chính xác trên ảnh. Nhưng khi số lượng tầng gia tăng, quá trình huấn luyện gặp rất nhiều trở ngại như việc mất gradient, bùng nổ gradient hoặc giảm hiệu năng suy luận vì kiến trúc dần trở nên rất phức tạp và khó kiểm soát [15].

Để giải quyết các nhược điểm này, một số kiến trúc CNN hiện nay được làm với mục tiêu nâng cao khả năng học nhưng vẫn đảm bảo hiệu quả tính toán. Và trong số đó là ResNet và EfficientNet, đây là hai họ mô hình có ảnh hưởng lớn trong lĩnh vực phân loại ảnh và thường được sử dụng làm backbone hoặc classifier trong các hệ thống Computer Vision hiện đại [16].

1.4.2 ResNet

ResNet được đề xuất vào năm 2016 nhằm giải quyết hiện tượng suy giảm hiệu năng khi tăng độ sâu của mạng nơ-ron [15]. Điểm khác biệt quan trọng của ResNet nằm ở việc sử dụng cơ chế kết nối tắt hay còn gọi là residual connection.

Trong kiến trúc CNN truyền thống, mỗi tầng phải học trực tiếp ánh xạ từ đầu vào sang đầu ra. ResNet thay đổi cách tiếp cận bằng việc yêu cầu mạng học phần dư residual mapping giữa đầu vào và đầu ra. Thông tin từ các tầng trước được truyền trực tiếp đến các tầng sau thông qua các kết nối tắt, giúp tín hiệu gradient lan truyền hiệu quả hơn trong quá trình huấn luyện [15].



Hình 1.7 Kiến trúc mạng ResNet

Về mặt toán học, đầu ra của một residual block được xác định bằng tổng của đầu vào và hàm biến đổi được học bởi các tầng bên trong khối. Cơ chế này giúp giảm hiện tượng mất gradient, cho phép xây dựng các mạng rất sâu mà vẫn duy trì khả năng hội tụ ổn định.


Nhờ kiến trúc residual, ResNet đạt được kết quả vượt trội trên nhiều bộ dữ liệu chuẩn như ImageNet và trở thành nền tảng cho nhiều nghiên cứu tiếp theo trong lĩnh vực Computer Vision [15]. Các biến thể phổ biến bao gồm ResNet18, ResNet34, ResNet50, ResNet101 và ResNet152, trong đó số phía sau biểu thị số lượng tầng của mạng.

Đối với bài toán phân loại biển báo giao thông, ResNet có khả năng học hiệu quả các đặc trưng hình học và màu sắc của biển báo. Kiến trúc này đặc biệt phù hợp khi áp dụng Transfer Learning do đã được tiền huấn luyện trên các bộ dữ liệu lớn và có khả năng thích nghi tốt với các tập dữ liệu chuyên biệt.

1.4.3 EfficientNet

Đúng là việc tăng chiều sâu hoặc độ rộng của mạng CNN sẽ giúp cải thiện nhiều hiệu năng, nhưng cách này không phải lúc nào cũng được tối ưu về mặt tài nguyên. Do đó nhằm giải quyết vấn đề đó, EfficientNet được đề xuất với khả năng mở rộng mô hình theo hướng cân bằng giữa các chiều sâu, rộng và độ phân giải ảnh của đối tượng đầu vào [16].

Thay vì chỉ tăng một chiều riêng, EfficientNet sử dụng phương pháp Compound Scaling để có thể cùng lúc điều chỉnh cả 3 chiều của mạng. Từ đó có thể tận dụng hiệu quả tài nguyên tính toán và đạt độ chính xác cao hơn nhiều các kiến trúc CNN truyền thống [16].



Hình 1.8 Kiến trúc EfficientNet

Kiến trúc nền tảng của EfficientNet được xây dựng dựa trên các khối MBConv, được thiết kế nhằm giảm chi phí tính toán nhưng vẫn duy trì khả năng biểu diễn đặc

trung tốt. Bên cạnh đó, cơ chế Squeeze-and-Excitation được tích hợp nhằm tăng cường khả năng học mối quan hệ giữa các kênh đặc trưng khác nhau.

1.4.4 So sánh ResNet và EfficientNet

ResNet và EfficientNet đều là những kiến trúc CNN hiệu quả, nhưng mỗi mô hình được xây dựng dựa trên triết lý thiết kế khác nhau.

ResNet tập trung giải quyết vấn đề huấn luyện mạng sâu thông qua residual connection. Kiến trúc này có tính ổn định cao, được hỗ trợ rộng rãi trong nhiều thư viện học sâu và thường được sử dụng làm lựa chọn mặc định trong các bài toán phân loại ảnh [15].

Trong khi đó, EfficientNet muốn hướng tới việc tăng hiệu quả sử dụng tài nguyên. Với số lượng tham số ít hơn nhiều, EfficientNet sẽ đạt độ chính xác tương đương hoặc nhiều khi cao hơn so với nhiều kiến trúc CNN truyền thống. Điều này đặc biệt hiệu quả trong hệ thống yêu cầu phần cứng có giới hạn cũng như về mặt bộ nhớ năng lực xử lý [17].

Nhưng EfficientNet thường yêu cầu quá trình tinh chỉnh siêu tham số cẩn thận hơn so với ResNet. Đối lập lại, ResNet có kiến trúc đơn giản, ổn định và dễ huấn luyện trên nhiều loại dữ liệu khác nhau.

1.4.5 Vai trò của ResNet và EfficientNet trong đề tài

Trong đề tài nhận diện và phân loại biển báo giao thông Việt Nam, ResNet và EfficientNet được lựa chọn làm các mô hình CNN phục vụ nhiệm vụ phân loại ảnh trong pipeline kết hợp detector–classifier. Sau khi YOLO xác định vị trí biển báo, vùng ảnh chứa đối tượng sẽ được cắt ra và đưa vào bộ phân loại để dự đoán lớp cuối cùng.

1.5 Chỉ số đánh giá mô hình

Việc đánh giá mô hình là bước quan trọng nhằm xác định mức độ hiệu quả của hệ thống nhận diện và phân loại biển báo giao thông.

Các chỉ số được sử dụng trong nghiên cứu bao gồm Precision, Recall, F1-score, Accuracy, IoU, mAP, Confusion Matrix và tốc độ suy luận. Đây là những chỉ số được sử dụng rất nhiều phổ biến trong các bài toán Computer Vision hiện đại, trong đó là Object Detection và Image Classification [20].

1.5.1 Precision

Precision dùng để đo mức độ chính xác của các dự đoán dương tính mà mô hình đưa ra. Chỉ số này cho biết trong số các đối tượng được mô hình nhận diện là đúng lớp hoặc đúng đối tượng, có bao nhiêu dự đoán thực sự chính xác [19].

Precision được tính theo công thức:

$$Precision = \frac{TP}{TP + FP}$$

Trong đó:

TP là số lượng mẫu được dự đoán đúng.

FP là số lượng mẫu được dự đoán sai nhưng vẫn được mô hình nhận diện là đúng.

1.5.2 Recall

Recall dùng để đo khả năng tìm kiếm đầy đủ các đối tượng thực sự tồn tại trong dữ liệu. Chỉ số này phản ánh tỷ lệ các đối tượng thực tế được mô hình phát hiện thành công [19].

Recall được xác định như sau:

$$Recall = \frac{TP}{TP + FN}$$

Trong đó:

FN là số lượng đối tượng thực tế nhưng không được mô hình phát hiện.

1.5.3 F1-score

Trong thực tế, Precision và Recall thường chưa phản ánh đầy đủ. Một mô hình có Precision cao chưa chắc đã đạt Recall cao và ngược lại. Vì vậy F1-score được sử dụng để đánh giá cân bằng giữa hai chỉ số này [19].

F1-score được tính bằng trung bình điều hòa của Precision và Recall:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Giá trị F1-score càng cao chứng tỏ mô hình duy trì được sự cân bằng tốt giữa khả năng phát hiện đầy đủ đối tượng và khả năng hạn chế các dự đoán sai.

1.5.4 Accuracy

Accuracy là tỷ lệ số mẫu được phân loại chính xác trên tổng số mẫu được đánh giá. Đây là chỉ số phổ biến trong các bài toán phân loại ảnh [19].

Accuracy được xác định theo công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó TN là số lượng mẫu âm tính được dự đoán chính xác.

1.5.5 IoU

Đối với bài toán phát hiện đối tượng, việc dự đoán đúng lớp là chưa đủ mà còn cần xác định chính xác vị trí của đối tượng trong ảnh. Do đó IoU là chỉ số đo lường mức độ chồng lấn giữa bounding box dự đoán và bounding box thực tế [20].

IoU được tính bằng tỷ lệ giữa diện tích giao nhau và diện tích hợp của hai vùng:

$$IoU = \frac{Area(B_{pred} \cap B_{gt})}{Area(B_{pred} \cup B_{gt})}$$

Trong đó:

B_{pred} là bounding box dự đoán.

B_{gt} là bounding box nhãn thực tế.

Giá trị IoU nằm trong khoảng từ 0 đến 1. IoU càng cao cho thấy vị trí dự đoán càng gần với vị trí thực tế của đối tượng. Trong các bài toán Object Detection, một dự đoán thường được xem là đúng khi giá trị IoU vượt qua một ngưỡng, ví dụ 0,5 [20].

1.5.6 mAP

mAP là chỉ số đánh giá quan trọng nhất trong các bài toán phát hiện đối tượng hiện đại [20]. Chỉ số này tổng hợp đồng thời khả năng định vị và khả năng phân loại của mô hình.

Đầu tiên, AP được tính cho từng lớp đối tượng dựa trên đường cong Precision–Recall. Sau đó, giá trị AP của tất cả các lớp được lấy trung bình để tạo thành mAP [18].

Có hai dạng mAP thường được sử dụng:

mAP@0.5: sử dụng ngưỡng IoU bằng 0,5.

mAP@0.5:0.95: trung bình kết quả tại nhiều ngưỡng IoU từ 0,5 đến 0,95.

Trong đó, mAP@0.5:0.95 được đánh giá khắt khe hơn vì yêu cầu mô hình phải dự đoán chính xác vị trí đối tượng ở nhiều mức độ khác nhau. Đây cũng là chỉ số được sử dụng phổ biến trong các phiên bản YOLO hiện nay [14].

1.5.7 Confusion Matrix

Confusion Matrix là công cụ trực quan giúp phân tích chi tiết kết quả phân loại của mô hình. Ma trận này thể hiện mối quan hệ giữa nhãn thực tế và nhãn dự đoán, từ đó cho phép xác định những lớp thường bị nhầm lẫn với nhau [19].

1.5.8 Tốc độ suy luận

Bên cạnh độ chính xác, khả năng triển khai thực tế của hệ thống còn phụ thuộc vào hiệu năng suy luận. Đối với các ứng dụng giao thông thông minh và hỗ trợ lái xe, hệ thống cần đưa ra kết quả trong thời gian ngắn để đáp ứng yêu cầu xử lý thời gian thực.

Một số chỉ số được sử dụng gồm: thời gian suy luận trung bình trên mỗi ảnh Inference Time, số khung hình xử lý trong một giây FPS.

CHƯƠNG 2: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

2.1 Dữ liệu nghiên cứu

2.1.1. Tổng quan


Bộ dữ liệu được sử dụng trong nghiên cứu là tập dữ liệu biển báo giao thông Việt Nam được công bố trên nền tảng Kaggle. Dữ liệu được tổ chức theo dạng mỗi ảnh đi kèm một tệp nhãn chứa thông tin lớp biển báo và tọa độ bounding box tương ứng. Hệ thống sử dụng tổng cộng 52 lớp biển báo giao thông Việt Nam, bao gồm các nhóm biển báo cấm, biển báo nguy hiểm, biển hiệu lệnh và biển chỉ dẫn.

Các nhãn được lưu theo cấu trúc gồm năm giá trị: mã lớp, tọa độ tâm theo trục ngang, tọa độ tâm theo trục dọc, chiều rộng và chiều cao của bounding box. Tất cả các tọa độ đều được chuẩn hóa trong khoảng từ 0 đến 1 theo kích thước ảnh đầu vào.

2.1.2 Thống kê bộ dữ liệu

Tập dữ liệu gốc gồm 3.216 ảnh. Sau khi áp dụng danh sách phân chia dữ liệu được sử dụng trong hệ thống, có 3.191 ảnh được đưa vào quá trình huấn luyện và đánh giá, trong khi 25 ảnh còn lại bị loại bỏ do có nhãn rỗng. Toàn bộ ảnh trong bộ dữ liệu đều được lưu dưới định dạng JPG và tất cả 52 lớp biển báo đều xuất hiện ít nhất một lần trong tập dữ liệu.

Tổng số đối tượng biển báo được gán nhãn là 8.334 bounding box. Trung bình mỗi ảnh chứa khoảng 2,6 biển báo, cho thấy dữ liệu có mức độ phức tạp tương đối cao do nhiều đối tượng có thể xuất hiện đồng thời trong cùng một khung hình. Việc tồn tại nhiều biển báo trong một ảnh giúp mô hình học được khả năng phát hiện đối tượng trong các bối cảnh giao thông thực tế thay vì chỉ tập trung vào các trường hợp đơn lẻ.



Hình 2.1 Trung bình biển báo mỗi ảnh


Dữ liệu được chia thành hai tập gồm tập huấn luyện và tập xác thực. Tập huấn luyện gồm 2.552 ảnh, chiếm khoảng 80% tổng số ảnh được sử dụng, tương ứng với 6.689 bounding box. Tập xác thực gồm 639 ảnh, chiếm 20%, tương ứng với 1.645 bounding box.

Bảng 2.1 Tỷ lệ chia dữ liệu


Tập dữ liệu	Số ảnh	Tỷ lệ (%)	Số bounding box
Train	2.552	80	6.689
Validation	639	20	1.645
Tổng cộng	3.191	100	8.334

Việc duy trì tỷ lệ phân chia xấp xỉ 80/20 giúp cân bằng giữa lượng dữ liệu phục vụ huấn luyện và khả năng đánh giá khách quan hiệu năng mô hình trên dữ liệu chưa từng xuất hiện trong quá trình học.

Phân bố số lượng mẫu giữa các lớp không hoàn toàn đồng đều. Một số lớp xuất hiện với tần suất rất cao như P.130, P.102 hoặc P.111, trong khi một số lớp chỉ xuất hiện với số lượng rất hạn chế.



Hình 2.2 15 lớp có số mẫu nhiều nhất




Hình 2.3 15 lớp có số mẫu ít nhất

Đối với bài toán Object Detection, việc cân bằng dữ liệu sẽ dễ gây overfitting hoặc làm mất giữ liệu quý giá, do đó việc giữ nguyên bộ dữ liệu gốc sẽ phản ánh thực thể phân bố biến báo trong môi trường giao thông.

2.2 Quy trình xử lý dữ liệu

2.2.1 Chuẩn hóa dữ liệu cho YOLO

Trước khi tiến hành huấn luyện mô hình YOLO, dữ liệu này sẽ được chuẩn hóa nhằm bảo đảm tính chính xác về cấu trúc dữ liệu, cấu trúc nhãn và đường dẫn truy cập. Quá trình chuẩn hóa này được tự động thông qua hệ thống mã nguồn xử lý dữ liệu, từ đó giảm đi các lỗi phát sinh trong quá trình huấn luyện và đánh giá mô hình.



Hình 2.4 Quy trình chuẩn hóa dữ liệu


Bước đầu của quá trình là xây dựng một cấu hình dữ liệu theo định dạng chuẩn của Ultralytic. Tập cấu hình này tạo ra config cho đường dẫn dữ liệu, danh sách tập train, tập test và số lượng mẫu cần nhận dạng. Thông tin này đóng vai trò quan trọng trong việc huấn luyện mô hình YOLO, khiến framework tự động nạp dữ liệu tự động trong giai đoạn train và test.

Sau khi đọc file cấu hình, hệ thống sẽ tiến hành kiểm tra và chuẩn hóa các đường dẫn của ảnh. Các đường dẫn dạng tương đối sẽ được chuyển thành tuyệt đối nhằm giúp truy cập dữ liệu ổn hơn trên các loại môi trường khác nhau. Cơ chế ánh xạ giữa ảnh và tệp nhãn này được thực hiện một cách tự động dựa trên loại tệp tương ứng giúp đảm bảo mỗi ảnh đều được liên kết với đúng thông tin của annotation.

2.2.2 Xây dựng tập dữ liệu Classification cho CNN

Khác với YOLO có khả năng học trực tiếp từ ảnh chứa nhiều đối tượng, các mô hình CNN trong nghiên cứu được thiết kế cho bài toán phân loại ảnh đơn đối tượng. Vì vậy, từ bộ dữ liệu phát hiện đối tượng ban đầu, cần xây dựng một tập dữ liệu mới gồm các ảnh chỉ chứa biển báo giao thông. Quá trình này được thực hiện tự động thông qua mô-đun tạo crop của hệ thống.

Một điểm khác với mô hình YOLO vốn có khả năng học trực tiếp từ ảnh chứa nhiều đối tượng, mô hình CNN được sử dụng ở đây được thiết kế cho bài toán phân loại ảnh đơn đối tượng. Do đó từ bộ dữ liệu ban đầu, cần phải xây dựng một hệ thống tập dữ liệu crop chỉ chứa biển báo giao thông. Quá trình này được thực hiện một cách tự động thông qua mã nguồn crop ảnh.



Hình 2.5 Xây dựng dữ liệu cho CNN

Mỗi bounding box hợp lệ tạo ra một ảnh crop độc lập. Các ảnh sau khi cắt được lưu vào thư mục tương ứng với lớp biển báo của chúng. Kết quả của quá trình xây dựng dữ liệu classification tạo ra 8334 ảnh biển báo tương ứng với toàn bộ số lượng bounding box của bộ dữ liệu detection. Do mỗi đối tượng được xem là một mẫu dữ liệu độc lập số lượng ảnh classification lớn hơn đáng kể so với số lượng ảnh gốc. Điều này giúp gia tăng số lượng mẫu huấn luyện cho các mô hình CNN, đồng thời cho phép bộ phân loại tập trung hoàn toàn vào đặc trưng của biển báo mà không bị ảnh hưởng bởi các thành phần nền trong ảnh.

Trước khi đưa vào quá trình huấn luyện, các ảnh crop này tiếp tục được tiền xử lý thông qua các phép biến đổi dữ liệu. Toàn bộ các ảnh được quy về kích thước 224x224

pixel với mục đích phù hợp với đầu vào của ResNet50 và EfficientNet-B0. Với tập huấn luyện, hệ thống sẽ áp dụng thêm một số kỹ thuật biến đổi như điều chỉnh độ tương phản và đổi ảnh ngẫu nhiên, điều này sẽ làm tăng rất nhiều sự đa dạng của dữ liệu. Và cuối cùng dữ liệu này sẽ được chuẩn hóa theo tham số của ImageNet để đảm bảo tương thích với trọng số huấn luyện trong quá trình Transfer Learning.


2.3 Thiết kế hệ thống

2.3.1 Kiến trúc tổng thể hệ thống

Hệ thống nhận diện và phân loại biển báo giao thông Việt Nam được thiết kế theo hướng mô-đun hóa để mục đích thuận lợi cho quá trình train, test và inference. Hệ thống có kiến trúc tổng thể có ba phần chính: khối chuẩn bị dữ liệu, khối huấn luyện mô hình và khối suy luận.

Quá trình xử lý bắt đầu từ tập dữ liệu gốc chứa ảnh và thông tin bounding box của từng biển báo, đến bước kiểm tra và chuẩn hóa nhãn, dữ liệu được sẽ được sử dụng để huấn luyện cho mô hình phát hiện đối tượng YOLO. Và đồng thời đó, các vùng ảnh chứa biển báo sẽ được cắt ra từ các bounding box để xây dựng một bộ dữ liệu cho việc phân loại bằng CNN. Cách xử lý này sẽ giúp khai thác cùng một bộ dữ liệu cho hai tính năng khác nhau, từ đó nâng cao chất lượng cho quá trình so sánh thực nghiệm.

Hệ thống bao gồm hai luồng kiểm thử để nhận diện độc lập. Đối với luồng kiểm thử một, sử dụng mô hình YOLO để thực hiện hai nhiệm vụ là phát hiện và phân loại biển báo trong một lần chạy. Luồng kiểm thử hai áp dụng kiến trúc kết hợp, trong đó YOLO sẽ có chức năng phát hiện còn CNN sẽ thực hiện nhiệm vụ quan trọng cuối nhất là phân loại vùng ảnh đã được phát hiện. Việc thực hiện song song hai luồng kiểm thử này sẽ cho phép đánh giá sự chênh lệch giữa độ chính xác và tốc độ nhận diện của biển báo.




Hình 2.6 Cấu trúc 2 luồng kiểm thử

Ở giai đoạn triển khai này, hệ thống cung cấp các giao diện suy luận độc lập cho từng luồng kiểm thử và một cơ chế benchmark dùng để so sánh kết quả giữa các mô hình. Thiết kế này không chỉ phục vụ mục đích nghiên cứu mà còn tạo tiền đề cho việc tích hợp vào các ứng dụng giao thông thông minh hoặc hệ thống hỗ trợ lái xe trong tương lai.

2.3.2 Luồng kiểm thử YOLO End-to-End

Luồng kiểm thử này được thiết kế theo hướng end-to-end, nghĩa là toàn bộ quá trình phát hiện và phân loại sẽ được thực hiện bởi một mô hình YOLO duy nhất. Đây là một hướng tiếp cận thuộc nhóm single-stage detector, thứ cho phép mô hình đồng thời phát hiện và gán nhãn lớp trong một lần chạy.

Trong giai đoạn chạy, đầu vào là ảnh sẽ được đưa trực tiếp vào mô hình YOLO. Sau khi đã trích xuất được đặc trưng thông qua backend và nhiều tầng, mô hình sẽ tiến hành cho ra các bounding box, xác suất từng lớp và confidence tương ứng.



Hình 2.7 Luồng kiểm thử YOLO End-to-End

Trong hệ thống này, với cùng một mô hình sẽ làm cả hai tính năng là phát hiện và phân loại, điều này giúp giảm độ phức tạp đi đáng kể, hạn chế các chi phí truyền tải dữ liệu giữa các mô-đun và tối ưu tốt độ suy luận. Đó là một ưu điểm cực quan trọng trong các ứng dụng thời gian thực như camera hành trình, camera giao thông và các hệ thống giám sát thời gian thực khác.

Tuy vậy, mô hình có khả năng phân loại phụ thuộc hoàn toàn vào tập đặc trưng học trong quá trình huấn luyện, do đó khi số lượng lớp lớn hoặc có nhiều biến báo giống nhau về màu sắc và kích thước, mô hình sẽ gặp khó khăn trong việc nhận diện chi tiết các đặc trưng nhỏ. Điển hình như là các tình huống giao thông mà biển báo ở rất xa.


Trong phạm vi thiết kế, các mô hình YOLOv5n, YOLOv8n và YOLOv11n được huấn luyện và đánh giá trên cùng bộ dữ liệu nhằm lựa chọn detector có hiệu năng tốt nhất cho luồng kiểm thử một. Các chỉ số được sử dụng bao gồm Precision, Recall, mAP@0.5, mAP@0.5:0.95, FPS, thời gian suy luận và kích thước mô hình.

2.3.3. Luồng kiểm thử YOLO kết hợp CNN

Khác với luồng kiểm thử đầu tiên luồng kiểm thử này áp dụng kiến trúc hai giai đoạn, trong đó nhiệm vụ phát hiện và nhiệm vụ phân loại được tách thành hai thành phần độc lập. Cách tiếp cận này tận dụng ưu thế của YOLO trong việc xác định vị trí đối tượng và khả năng học đặc trưng chuyên sâu của các mạng CNN hiện đại.

Ở giai đoạn đầu tiên, ảnh đầu vào được xử lý bởi mô hình YOLO để phát hiện vị trí các biển báo xuất hiện trong khung hình. Kết quả của bước này bao gồm các bounding box và độ tin cậy tương ứng. Thay vì sử dụng trực tiếp nhãn lớp từ YOLO, hệ thống chỉ khai thác thông tin vị trí đối tượng.

Sau khi xác định được vùng chứa biển báo, ảnh sẽ được cắt theo tọa độ bounding box và chuẩn hóa kích thước trước khi đưa vào bộ phân loại CNN. Trong nghiên cứu này, hai kiến trúc được lựa chọn để đánh giá là ResNet50 và EfficientNet-B0. Các mô hình được huấn luyện trên tập dữ liệu classification được xây dựng từ các ảnh crop thu được trong quá trình tiền xử lý dữ liệu.



Hình 2.8 Kiểm thử YOLO kết hợp CNN

Việc tách biệt hai nhiệm vụ mang lại một số lợi thế đáng kể. Bộ phân loại CNN được huấn luyện trực tiếp trên ảnh biển báo đã được cắt khỏi bối cảnh xung quanh, nhờ đó có thể tập trung học các đặc trưng hình học, màu sắc và ký hiệu đặc thù của từng lớp biển báo. Điều này đặc biệt hữu ích khi xử lý các lớp có mức độ tương đồng cao hoặc các biển báo chỉ khác nhau ở một số chi tiết nhỏ.

Nhưng đổi lại, luồng kiểm thử này sẽ tạo ra thêm chi phí để tính toán do phải thực hiện tận hai lần suy luận liên tiếp. Và ngoài thời gian xử lý của mô hình YOLO, hệ thống còn phải thực hiện bước crop ảnh và phân loại bằng CNN. Do đó tốc độ suy luận sẽ thấp hơn so với mô hình end-to-end, nhất là khi số lượng đối tượng nhiều.

Trong phạm vi nghiên cứu này, luồng kiểm thử được xây dựng với mục tiêu đánh giá nếu bổ sung một mô hình phân loại có giúp cải thiện được chất lượng biển báo hay không. Kết quả sẽ được dùng để so sánh trực tiếp với luồng kiểm thử một với các tiêu chí về độ chính xác, tốc độ xử lý và kích thước mô hình trong triển khai thực tế.

2.4 Xây dựng mô hình YOLO

2.4.1 Các mô hình YOLO sử dụng

Nhằm đánh giá khả năng ứng dụng của các phiên bản YOLO hiện đại đối với bài toán nhận diện biển báo giao thông Việt Nam, ba mô hình thuộc nhóm nano gồm YOLOv5n, YOLOv8n và YOLOv11n đã được lựa chọn. Đây đều là các biến thể được thiết kế theo hướng giảm số lượng tham số và tối ưu tốc độ suy luận, phù hợp với các hệ thống yêu cầu xử lý thời gian thực.


Cả ba mô hình đều được huấn luyện theo phương pháp transfer learning thông qua các trọng số tiền huấn luyện. Việc sử dụng pretrained model giúp tận dụng các đặc

trung đã học từ các bộ dữ liệu lớn, từ đó rút ngắn thời gian hội tụ và nâng cao khả năng tổng quát hóa trên bộ dữ liệu biển báo giao thông Việt Nam.

2.4.2 Data Augmentation trong huấn luyện YOLO

Data Augmentation là một kỹ thuật quan trọng trong quá trình huấn luyện các mô hình học sâu nhằm cải thiện khả năng tổng quát hóa và giảm hiện tượng quá khớp. Đối với bài toán nhận diện biển báo giao thông, dữ liệu thu thập trong thực tế thường có sự đa dạng lớn về điều kiện ánh sáng, khoảng cách quan sát, góc chụp và môi trường xung quanh. Do đó, việc tăng cường dữ liệu giúp mô hình học được các đặc trưng ổn định hơn trước những biến đổi này.

Kỹ thuật tăng cường dữ liệu được nghiên cứu và đánh giá là Mosaic Augmentation. Đây là phương pháp ghép bốn ảnh huấn luyện khác nhau thành một ảnh mới, đồng thời điều chỉnh lại vị trí và nhãn của các đối tượng tương ứng. Quá trình này tạo ra những mẫu dữ liệu đa dạng hơn so với dữ liệu gốc mà không cần thu thập thêm ảnh mới.



Hình 2.9 Kỹ thuật Mosaic

Khi áp dụng Mosaic đối tượng có thể xuất hiện ở nhiều vị trí và tỷ lệ khác nhau trong cùng một ảnh huấn luyện. Điều này giúp mô hình học được khả năng phát hiện đối


tượng ở nhiều kích thước khác nhau, đặc biệt là các đối tượng nhỏ. Đối với bài toán biển báo giao thông, lợi ích này có ý nghĩa quan trọng vì biển báo thường chỉ chiếm một vùng nhỏ trong ảnh và có thể xuất hiện ở nhiều khoảng cách quan sát khác nhau.

Bên cạnh việc làm tăng tính đa dạng của dữ liệu, Mosaic còn giúp mô hình tiếp xúc với nhiều bối cảnh khác nhau trong mỗi lần cập nhật trọng số. Vì thế khả năng tổng quát hóa của mô hình được cải thiện và hiện tượng phụ thuộc quá mức vào một số mẫu dữ liệu cụ thể được giảm thiểu.

2.4.3 Cấu hình huấn luyện YOLO

Quá trình huấn luyện YOLO được thực hiện trên bộ dữ liệu gồm 52 lớp biển báo giao thông Việt Nam đã được chuẩn hóa theo định dạng YOLO. Dữ liệu được chia thành hai tập riêng biệt gồm tập train và test nhằm phục vụ quá trình học và đánh giá mô hình.

Để đảm bảo tính nhất quán trong quá trình benchmark, các mô hình YOLO được huấn luyện theo cùng một quy trình. Trước tiên, mô hình được khởi tạo từ các trọng số tiền huấn luyện. Sau đó, dữ liệu huấn luyện được đưa vào mạng để thực hiện quá trình tối ưu hóa tham số. Sau mỗi epoch, mô hình được đánh giá trên tập xác thực nhằm theo dõi khả năng hội tụ và lựa chọn trọng số tốt nhất.



Hình 2.10 Luồng đánh giá YOLO

Trong phạm vi nghiên cứu này, số epoch được cố định ở mức 100 cho tất cả các mô hình nhằm tạo điều kiện cho quá trình hội tụ diễn ra đầy đủ.

Bên cạnh việc so sánh các kiến trúc YOLO đề tài còn khảo sát ảnh hưởng của một số siêu tham số quan trọng đến hiệu năng mô hình. Các tham số được lựa chọn dựa trên những yếu tố có ảnh hưởng trực tiếp đến chất lượng phát hiện đối tượng và chi phí tính toán.

Bảng 2.2 Đối tượng khảo sát của YOLO

Đối tượng khảo sát	Giá trị khảo sát
Model Yolo	Yolov5n, Yolov8n, Yolov11n
Epoch	100
Image Size	416, 640, 800

Đối tượng khảo sát	Giá trị khảo sát
Model Yolo	Yolov5n, Yolov8n, Yolov11n
Learning Rate	0.001, 0.005, 0.01
Batch Size	8, 16, 32
Mosaic	0, 1

Trong đó kích thước ảnh đầu vào sẽ ảnh hưởng trực tiếp đến khả năng phát hiện đối tượng chi tiết. Learning rate sẽ quyết định tốc độ cập nhật trọng số trong quá trình huấn luyện. Batch size sẽ tác động đến sự ổn định của quá trình học và khả năng khai thác tài nguyên phần cứng. Đối với Mosaic, đây là một tham số đóng vai trò tăng cường dữ liệu cho hiệu năng của mô hình.

2.5 Xây dựng mô hình CNN

2.5.1 ResNet50

Trong phạm vi nghiên cứu này ResNet50 được sử dụng dưới dạng mô hình tiền huấn luyện trên ImageNet. Lớp Fully Connected cuối cùng của mạng được thay thế bằng một lớp phân loại mới có 52 đầu ra tương ứng với 52 lớp biển báo giao thông Việt Nam. Việc thay đổi lớp đầu ra giúp mô hình thích nghi với bài toán phân loại cụ thể của đề tài.

Và bên cạnh đó nghiên cứu áp dụng phương pháp Transfer Learning để tận dụng các đặc trưng đã học từ tập dữ liệu ImageNet. Trong quá trình huấn luyện, mô hình có thể được sử dụng theo hai chiến lược khác nhau gồm đóng băng phần backbone và chỉ huấn luyện lớp phân loại cuối hoặc tinh chỉnh toàn bộ mạng. Cách tiếp cận này cho phép đánh giá khả năng thích nghi của ResNet50 đối với dữ liệu biển báo giao thông Việt Nam.

2.5.2 EfficientNet-B0


EfficientNet-B0 được lựa chọn vì đặc điểm cân bằng giữa độ chính xác và tài nguyên. Nếu so với các mạng CNN có độ sâu lớn, EfficientNet-B0 sẽ đạt hiệu quả tương đương và đôi khi hiệu quả hơn trong khi sở hữu bộ nhớ và thời gian suy luận thấp hơn. Vì thế điều này cực đặc biệt quan trọng đối với hệ thống nhận diện biển báo giao thông khi bị hạn chế về mặt tài nguyên phần cứng.

Trong phạm vi đề tài EfficientNet-B0 được sử dụng như đại diện cho nhóm kiến trúc CNN hiện đại hướng đến tối ưu hiệu quả tính toán. Kết quả thực nghiệm sẽ được sử dụng để so sánh với ResNet50 nhằm đánh giá mức độ phù hợp của từng kiến trúc đối với bài toán phân loại biển báo giao thông Việt Nam.

2.5.3 Cấu hình huấn luyện

Dữ liệu huấn luyện của CNN được xây dựng từ các ảnh biển báo đã được crop theo thông tin bounding box của bộ dữ liệu gốc. Mỗi ảnh crop được gán nhãn tương ứng với lớp biển báo và được tổ chức theo cấu trúc thư mục phù hợp với cơ chế ImageFolder của PyTorch.

Quá trình huấn luyện được thực hiện theo quy trình gồm các bước: xây dựng tập dữ liệu, áp dụng các phép biến đổi ảnh, khởi tạo mô hình tiền huấn luyện, thực hiện Transfer Learning và tối ưu hóa các tham số của mạng.



Hình 2.11 Luồng đánh giá CNN

Các mô hình được huấn luyện bằng thuật toán tối ưu Adam kết hợp với hàm mất mát Cross-Entropy Loss. Đây là lựa chọn phổ biến đối với các bài toán phân loại đa lớp nhờ khả năng hội tụ nhanh và ổn định.

Để đánh giá được sự ảnh hưởng của các tham số huấn luyện đến khả năng phân loại, hệ thống tiến hành khảo sát các siêu tham số quan trọng gồm learning rate và các chiến lược Transfer Learning. Trong đó learning rate được đánh giá ở các mức khác nhau nhằm khảo sát giá trị tốt nhất. Hai chiến lược gồm đóng băng backbone và fine tune toàn bộ mạng được xem xét để đánh giá sự thích nghi của mô hình đối với bộ dữ liệu biến báo giao thông.

Bảng 2.3 Đối tượng khảo sát của CNN


Đối tượng khảo sát	Giá trị khảo sát
Model CNN	ResNet50, EfficientNet-B0
Learning Rate	0,0001; 0,001; 0,01
Transfer Learning Strategy	Frozen Backbone, Fine-tuning

Sau khi đã hoàn thành huấn luyện, các mô hình sẽ được đánh giá thông qua các chỉ số Accuracy, Precision, Recall, F1-score, thời gian suy luận và kích thước mô hình. Trong đó, F1-score được lựa chọn làm tiêu chí chính để so sánh và lựa chọn mô hình do chỉ số này phản ánh đồng thời khả năng dự đoán chính xác và khả năng bao phủ đầy đủ các lớp dữ liệu.

CHƯƠNG 3: THỰC NGHIỆM VÀ KẾT QUẢ

3.1 Môi trường và kịch bản thực nghiệm

Quá trình thực nghiệm được tổ chức thành ba giai đoạn chính. Giai đoạn thứ nhất tập trung đánh giá các mô hình YOLOv5n, YOLOv8n và YOLOv11n nhằm lựa chọn mô hình phát hiện đối tượng phù hợp nhất cho bài toán nhận diện biển báo giao thông. Các mô hình được huấn luyện theo cùng một quy trình với số epoch cố định, đồng thời được đánh giá thông qua các chỉ số Precision, Recall, mAP@0.5, mAP@0.5:0.95, FPS, thời gian suy luận và kích thước mô hình. Sau khi xác định được mô hình có hiệu năng tốt nhất, nghiên cứu tiếp tục khảo sát ảnh hưởng của các siêu tham số như kích thước ảnh đầu vào, learning rate, batch size và kỹ thuật Mosaic Augmentation nhằm xác định cấu hình huấn luyện tối ưu.



Hình 3.1 Luồng đánh giá tổng thể

Giai đoạn thứ hai được thực hiện trên tập dữ liệu phân loại ảnh đã được tạo từ các vùng crop biển báo. Hai kiến trúc CNN gồm ResNet50 và EfficientNet-B0 được huấn

luyện bằng phương pháp Transfer Learning để đánh giá khả năng nhận dạng các lớp biển báo giao thông. Các mô hình được so sánh dựa trên Accuracy, Precision, Recall, F1-score, thời gian suy luận và kích thước mô hình. Song song với việc đánh giá kiến trúc mạng, nghiên cứu cũng khảo sát ảnh hưởng của learning rate và chiến lược huấn luyện, bao gồm đóng băng backbone và fine-tuning toàn bộ mạng, nhằm xác định cấu hình mang lại hiệu quả cao nhất.


Giai đoạn cuối cùng tập trung đánh giá hiệu năng của hai luồng kiểm thử nhận diện biển báo. Luồng kiểm thử thứ nhất sử dụng mô hình YOLO theo hướng end-to-end, trong khi luồng kiểm thử thứ hai kết hợp bộ phát hiện YOLO với bộ phân loại CNN. Việc so sánh được thực hiện trên các tiêu chí về độ chính xác nhận dạng, khả năng phát hiện đối tượng, tốc độ suy luận, số khung hình xử lý trên giây và kích thước mô hình. Kịch bản này cho phép đánh giá sự đánh đổi giữa tốc độ xử lý và chất lượng nhận dạng, từ đó xác định hướng tiếp cận phù hợp hơn đối với các hệ thống nhận diện biển báo giao thông trong điều kiện triển khai thực tế.

3.2 Kết quả thực nghiệm YOLO

3.2.1 Đánh giá baseline các mô hình YOLO

Khi Mosaic không được kích hoạt, YOLOv8n đạt giá trị $mAP@0.5:0.95$ cao nhất là 0,760, đồng thời cũng cho tốc độ suy luận tốt nhất với 145,4 FPS. Mặc dù YOLOv11n đạt Recall cao hơn, kết quả $mAP@0.5:0.95$ vẫn thấp hơn YOLOv8n. Trong khi đó, YOLOv5n cho thấy ưu thế về kích thước mô hình nhưng lại đạt giá trị $mAP@0.5:0.95$ thấp nhất trong ba kiến trúc được khảo sát.

Kết quả tiếp tục được duy trì khi Mosaic được áp dụng trong quá trình huấn luyện. YOLOv8n đạt $mAP@0.5:0.95$ bằng 0,767, cao hơn cả YOLOv5n và YOLOv11n. Chênh lệch giữa YOLOv8n và YOLOv11n không lớn, tuy nhiên YOLOv8n vẫn duy trì tốc độ suy luận cao hơn đáng kể. Điều này cho thấy khả năng cân bằng giữa độ chính xác và hiệu năng xử lý của YOLOv8n tốt hơn so với các mô hình còn lại.



Hình 3.2 kết quả baseline của YOLO


Phân tích riêng trên YOLOv8n cho thấy Mosaic mang lại tác động tích cực đối với chất lượng phát hiện. Khi chuyển từ cấu hình không sử dụng Mosaic sang sử dụng Mosaic, Recall tăng từ 0,944 lên 0,957, trong khi mAP@0.5:0.95 tăng từ 0,760 lên 0,767. Đổi lại, Precision và FPS giảm nhẹ, tuy nhiên mức suy giảm không đáng kể so với lợi ích về khả năng phát hiện đối tượng.

Từ các kết quả thu được, YOLOv8n được lựa chọn làm mô hình đại diện cho nhóm YOLO trong các thí nghiệm tiếp theo. Mô hình này không chỉ đạt giá trị mAP@0.5:0.95 cao nhất mà còn duy trì tốc độ suy luận vượt trội, phù hợp với yêu cầu triển khai trong các hệ thống nhận diện biển báo giao thông thời gian thực.

3.2.2 Phân tích ảnh hưởng Hyperparameter

Sau khi lựa chọn được YOLOv8n là kiến trúc phù hợp nhất, nghiên cứu tiếp tục khảo sát ảnh hưởng của các siêu tham số quan trọng gồm kích thước ảnh đầu vào, learning rate và batch size.


Kích thước ảnh đầu vào được khảo sát tại ba mức 416, 640 và 800 pixel. Kết quả cho thấy khi tăng kích thước ảnh từ 416 lên 800, giá trị $mAP@0.5:0.95$ tăng từ 0,701 lên 0,781. Mức cải thiện gần 8 điểm phần trăm cho thấy khả năng phát hiện các biển báo kích thước nhỏ được nâng cao đáng kể khi mô hình được cung cấp nhiều thông tin chi tiết hơn từ ảnh đầu vào.



Hình 3.3 Kết quả ảnh hưởng của imgsize

Tuy nhiên, độ chính xác cao hơn đi kèm với sự suy giảm về tốc độ xử lý. FPS giảm từ 177,2 xuống còn 129,5 khi kích thước ảnh tăng lên 800. Điều này phản ánh sự đánh đổi thường gặp trong các bài toán Object Detection giữa chất lượng dự đoán và chi phí tính toán. Dù vậy, mức FPS đạt được vẫn đủ đáp ứng các yêu cầu xử lý thời gian thực, do đó kích thước ảnh 800 được lựa chọn cho các thí nghiệm tiếp theo.


Learning rate được khảo sát ở ba mức 0,001; 0,005 và 0,01. Kết quả cho thấy các chỉ số Precision, Recall, mAP@0.5 và mAP@0.5:0.95 gần như không thay đổi giữa các cấu hình. Điều này cho thấy mô hình đã hội tụ ổn định và không quá nhạy cảm với các giá trị learning rate nằm trong khoảng khảo sát.



Hình 3.4 Kết quả ảnh hưởng của learning

Mặc dù chất lượng dự đoán tương đương nhau, learning rate 0,001 đạt tốc độ suy luận cao nhất với 131,6 FPS. Trên cơ sở tiêu chí lựa chọn của hệ thống cấu hình này được sử dụng trong giai đoạn khảo sát batch size.

Batch size được đánh giá tại ba mức 8, 16 và 32. Kết quả thực nghiệm cho thấy batch size có ảnh hưởng rõ rệt đến khả năng tổng quát hóa của mô hình. Cấu hình batch size 32 đạt giá trị mAP@0.5:0.95 bằng 0,783, cao nhất trong toàn bộ các thí nghiệm YOLO, đồng thời đạt Recall 0,973.



Hình 3.5 kết quả ảnh hưởng batchsize

Trong khi đó, batch size 8 cho kết quả thấp hơn đáng kể với mAP@0.5:0.95 chỉ đạt 0,771 và tốc độ suy luận giảm xuống còn 98,7 FPS. Điều này cho thấy việc sử dụng batch size lớn hơn giúp quá trình cập nhật trọng số ổn định hơn, từ đó cải thiện chất lượng học của mô hình trên bộ dữ liệu biến báo giao thông.


Tổng hợp các kết quả khảo sát cho thấy kích thước ảnh đầu vào là tham số có tác động mạnh nhất đến hiệu năng phát hiện. Learning rate chỉ tạo ra khác biệt nhỏ trong phạm vi khảo sát, trong khi batch size ảnh hưởng trực tiếp đến khả năng tổng quát hóa và độ chính xác cuối cùng của mô hình.

3.2.3 Lựa chọn mô hình YOLO tốt nhất

Hệ thống lựa chọn mô hình tốt nhất dựa trên tiêu chí ưu tiên giá trị mAP@0.5:0.95. Trong trường hợp các mô hình có cùng giá trị mAP@0.5:0.95, hệ thống tiếp tục so sánh mAP@0.5 và cuối cùng là FPS để đưa ra quyết định. Tiêu chí này phù hợp với đặc thù của bài toán Object Detection, trong đó mAP@0.5:0.95 phản ánh đồng thời khả năng định vị và phân loại đối tượng ở nhiều ngưỡng IoU khác nhau.

Sau bốn giai đoạn benchmark liên tiếp, cấu hình đạt kết quả tốt nhất là YOLOv8n với kích thước ảnh đầu vào 800, learning rate 0,001, batch size 32 và Mosaic được kích

hoạt trong quá trình huấn luyện. Mô hình đạt Precision 0,947, Recall 0,973, mAP@0.5 bằng 0,987 và mAP@0.5:0.95 bằng 0,783. Tốc độ suy luận đạt 126,2 FPS với kích thước mô hình khoảng 6 MB.



Hình 3.6 Kết quả so với baseline

So với cấu hình YOLOv8n ban đầu sử dụng kích thước ảnh 640, learning rate 0,005 và batch size 16, mô hình tối ưu giúp mAP@0.5:0.95 tăng từ 0,767 lên 0,783. Recall cũng tăng từ 0,957 lên 0,973, cho thấy khả năng phát hiện đầy đủ các biển báo được cải thiện đáng kể. Mặc dù FPS giảm khoảng 14 khung hình mỗi giây do kích thước ảnh lớn hơn, tốc độ xử lý vẫn duy trì ở mức cao và hoàn toàn đáp ứng yêu cầu triển khai thực tế.


Từ những kết quả trên, YOLOv8n với cấu hình tối ưu được lựa chọn làm mô hình phát hiện biển báo chính thức của đề tài. Trọng số này được sử dụng trực tiếp trong luồng kiểm thử 1 và đồng thời đóng vai trò detector trong luồng kiểm thử 2 để phục vụ các thí nghiệm so sánh ở các mục tiếp theo.

3.3 Kết quả thực nghiệm CNN

3.3.1 Đánh giá baseline ResNet50 và EfficientNet-B0

Hai mô hình được huấn luyện với cùng cấu hình gồm 50 epoch, batch size 32, learning rate 0,001 và chiến lược fine-tuning toàn bộ mạng. Kết quả thu được cho thấy cả hai kiến trúc đều đạt hiệu năng rất cao trên tập dữ liệu biên báo giao thông, với Accuracy đều vượt mức 98%.

Kết quả cho thấy EfficientNet-B0 đạt F1-score bằng 0,989, cao hơn 0,007 so với ResNet50. Mặc dù mức chênh lệch không quá lớn, đây là sự cải thiện đáng kể trong bối cảnh cả hai mô hình đều đã đạt độ chính xác rất cao. Đồng thời, Accuracy của EfficientNet-B0 đạt 98,9%, cao hơn mức 98,5% của ResNet50.



Hình 3.7 Kết quả baseline của CNN


Một kết quả đáng chú ý khác là sự khác biệt rất lớn về kích thước mô hình. ResNet50 yêu cầu khoảng 90,40 MB bộ nhớ lưu trữ, trong khi EfficientNet-B0 chỉ chiếm 15,85 MB. Điều này đồng nghĩa EfficientNet-B0 nhỏ hơn khoảng 82% nhưng vẫn đạt hiệu năng phân loại cao hơn.

Xét tổng thể trên cả độ chính xác tốc độ xử lý và chi phí lưu trữ, EfficientNet-B0 cho thấy hiệu quả vượt trội và trở thành ứng viên phù hợp hơn cho các thí nghiệm tối ưu hóa tiếp theo.

3.3.2 Phân tích Hyperparameter

Sau khi xác định EfficientNet-B0 là kiến trúc có hiệu năng tốt nhất, nghiên cứu tiếp tục khảo sát ảnh hưởng của các siêu tham số quan trọng gồm learning rate và chiến lược Transfer Learning.

Learning rate được khảo sát tại ba mức 0,0001; 0,001 và 0,01 trong khi các tham số còn lại được giữ cố định. Kết quả cho thấy learning rate có ảnh hưởng đáng kể đến quá trình hội tụ của mô hình. Khi learning rate tăng lên 0,01, hiệu năng phân loại suy giảm mạnh với F1-score chỉ còn 0,899. Validation Loss tăng lên 0,208 cho thấy mô hình gặp khó khăn trong việc tối ưu hóa và không thể hội tụ ổn định. Điều này phản ánh hiện tượng cập nhật trọng số quá lớn khiến quá trình học dao động quanh nghiệm tối ưu.




Hình 3.8 Kết quả ảnh hưởng của learning

Ngược lại, hai cấu hình 0,0001 và 0,001 đều đạt kết quả rất cao. Learning rate 0,0001 cho Accuracy và Validation Loss tốt nhất, tuy nhiên F1-score không vượt qua cấu

hình 0,001. Do hệ thống sử dụng F1-score làm tiêu chí ưu tiên, learning rate 0,001 tiếp tục được lựa chọn cho giai đoạn khảo sát tiếp theo.

Hai chiến lược transfer learning được đánh giá gồm Frozen Backbone và Fine-Tuning. Kết quả cho thấy Fine-Tuning đạt F1-score cao hơn so với Frozen Backbone. Mặc dù mức chênh lệch chỉ khoảng 0,001, điều này cho thấy việc cho phép toàn bộ mạng tiếp tục cập nhật trọng số giúp mô hình thích nghi tốt hơn với đặc trưng riêng của dữ liệu biên báo giao thông Việt Nam.



Hình 3.9 Ảnh hưởng của transfer learning

Trong khi đó, Frozen Backbone đạt Train Loss thấp hơn nhưng không mang lại khả năng tổng quát hóa tương ứng trên tập xác thực. Điều này cho thấy các đặc trưng học từ ImageNet tuy hữu ích nhưng vẫn cần được tinh chỉnh để phù hợp với bài toán nhận dạng biển báo có nhiều lớp tương đồng về hình dạng và màu sắc.

Tổng hợp kết quả khảo sát cho thấy learning rate là tham số có tác động mạnh nhất đến chất lượng phân loại. Chiến lược Fine-Tuning mang lại cải thiện nhỏ hơn nhưng vẫn giúp nâng cao hiệu năng tổng thể của mô hình. Vì vậy, cấu hình gồm learning rate 0,001 và Fine-Tuning được lựa chọn làm cấu hình tối ưu cho bộ phân loại CNN.

3.3.3 Lựa chọn mô hình CNN tốt nhất

Sau ba giai đoạn benchmark liên tiếp, mô hình được lựa chọn là EfficientNet-B0 với learning rate 0,001, batch size 32, kích thước đầu vào 224×224 và chiến lược Fine-Tuning. Mô hình đạt Accuracy 98,9%, Precision 99,2%, Recall 98,7% và F1-score 98,9%.

So với ResNet50, EfficientNet-B0 cải thiện F1-score thêm 0,007 điểm, Accuracy tăng 0,004 điểm và Precision tăng 0,009 điểm. Đồng thời, kích thước mô hình giảm từ 90,40 MB xuống còn 15,85 MB. Đây là một lợi thế đáng kể khi triển khai trên các hệ thống có giới hạn về bộ nhớ hoặc yêu cầu xử lý thời gian thực.

Kết quả thực nghiệm cho thấy EfficientNet-B0 đạt được sự cân bằng tốt giữa độ chính xác, tốc độ suy luận và chi phí tính toán với hiệu năng phân loại đạt gần 99% trên 52 lớp biên báo giao thông Việt Nam.

3.4 Đánh giá các hướng tiếp cận

3.4.1 Phương pháp đánh giá

Do cả hai pipeline đều sử dụng cùng một mô hình YOLOv8n cho nhiệm vụ phát hiện đối tượng, khả năng định vị biên báo được xem là tương đương. Vì vậy, trọng tâm của quá trình đánh giá được đặt vào hiệu quả nhận dạng cuối cùng của toàn bộ hệ thống cũng như khả năng triển khai trong thực tế.


Do đó việc lựa chọn được thực hiện theo thứ tự ưu tiên gồm F1-macro, FPS và kích thước mô hình. Trong trường hợp chênh lệch về F1-macro không đáng kể, pipeline có tốc độ xử lý cao hơn và yêu cầu tài nguyên thấp hơn sẽ được ưu tiên lựa chọn.

3.4.2 Kết quả đánh giá

Sau khi lựa chọn được mô hình YOLO tốt nhất và mô hình CNN tốt nhất từ các giai đoạn thực nghiệm trước, nghiên cứu tiếp hành xây dựng và đánh giá hai pipeline nhận diện biên báo giao thông hoàn chỉnh. Luồng kiểm thử đầu tiên sử dụng mô hình

YOLOv8n theo hướng end-to-end, trong khi luồng kiểm thử 2 kết hợp YOLOv8n làm bộ phát hiện đối tượng và EfficientNet-B0 làm bộ phân loại cuối cùng.

Do cùng sử dụng một mô hình YOLOv8n cho nhiệm vụ phát hiện đối tượng nên hai pipeline đạt kết quả tương đương về khả năng định vị biên báo. Cả hai đều đạt $mAP@0.5$ bằng 0,987 và $mAP@0.5:0.95$ bằng 0,783. Điều này cho thấy chất lượng phát hiện đối tượng không bị ảnh hưởng bởi việc bổ sung bộ phân loại CNN ở giai đoạn sau.



Hình 3.10 Kết quả đánh giá luồng CNN

Sự khác biệt chủ yếu xuất hiện ở nhiệm vụ phân loại biên báo. Luồng kiểm thử 2 đạt F1-macro bằng 0,989, cao hơn đáng kể so với mức 0,960 của luồng đầu tiên. Precision và Recall cũng tăng tương ứng từ 0,947 lên 0,992 và từ 0,973 lên 0,987. Kết quả này cho thấy EfficientNet-B0 có khả năng khai thác các đặc trưng chi tiết của biên báo hiệu quả hơn khi được huấn luyện trực tiếp trên tập dữ liệu classification.

Tuy nhiên thời gian suy luận trung bình của luồng kiểm thử 2 đạt 27,99 ms trên mỗi ảnh, cao hơn khoảng 3,5 lần so với luồng kiểm thử 1. FPS giảm từ 126,2 xuống còn 35,7 do hệ thống phải thực hiện thêm các bước cắt ảnh và phân loại bằng CNN. Đồng thời, kích thước mô hình tăng từ 6,0 MB lên 21,9 MB khi cần lưu trữ cả detector và classifier.

3.4.3 So sánh và thảo luận

Kết quả thực nghiệm cho thấy mỗi hướng tiếp cận sở hữu những ưu điểm riêng và phù hợp với các mục tiêu triển khai khác nhau.

Đối với luồng kiểm thử 1, ưu thế lớn nhất nằm ở tốc độ xử lý. Việc sử dụng một mô hình duy nhất cho toàn bộ quá trình nhận diện giúp giảm chi phí tính toán, hạn chế độ trễ và đơn giản hóa kiến trúc hệ thống. Với tốc độ đạt 126,2 FPS, pipeline này hoàn toàn đáp ứng các yêu cầu xử lý thời gian thực trong các ứng dụng như camera giao thông, hệ thống giám sát giao lộ hoặc hỗ trợ lái xe nâng cao.

Trong khi đó, luồng kiểm thử 2 cho thấy hiệu quả vượt trội về chất lượng nhận dạng. F1-macro tăng từ 0,960 lên 0,989, tương đương mức cải thiện gần 3 điểm phần trăm. Precision đạt 0,992 cho thấy số lượng dự đoán sai giảm đáng kể so với mô hình end-to-end. Điều này phản ánh lợi thế của kiến trúc hai giai đoạn, trong đó bộ phân loại CNN được huấn luyện chuyên biệt trên các ảnh biển báo đã được tách khỏi bối cảnh xung quanh, giúp mô hình tập trung vào các đặc trưng hình dạng, màu sắc và ký hiệu của từng lớp biển báo.

Mặc dù vậy, chi phí đánh đổi là khá rõ ràng. Luồng kiểm thử 2 yêu cầu thực hiện nhiều bước xử lý liên tiếp gồm phát hiện đối tượng, cắt vùng ảnh và phân loại bằng CNN. Điều này làm tăng độ trễ suy luận lên gần 28 ms mỗi ảnh và khiến kích thước mô hình lớn hơn khoảng 3,6 lần so với luồng kiểm thử 1. Trong các hệ thống có tài nguyên phần cứng hạn chế hoặc yêu cầu tốc độ xử lý rất cao, đây là một yếu tố cần được cân nhắc.

Xét theo tiêu chí lựa chọn của đề tài, tiêu chí F1-macro của luồng kiểm thử 2 đạt kết quả cao hơn không đáng kể nhưng tốc độ xử lý thấp hơn nhiều so với luồng kiểm thử 1, do đó luồng kiểm thử 1 được lựa chọn là hướng tiếp cận cuối cùng của đề tài nhờ đạt chất lượng nhận dạng tổng thể tốt nhất trên bộ dữ liệu biển báo giao thông Việt Nam.

3.5 Triển khai hệ thống Web

3.5.1 Kiến trúc hệ thống

Kiến trúc tổng thể của hệ thống bao gồm ba tầng chính: tầng giao diện người dùng (Frontend), tầng dịch vụ ứng dụng (Backend API) và tầng suy luận mô hình (Inference Service).

Khi người dùng tải lên một ảnh hoặc video, dữ liệu được gửi đến máy chủ thông qua các API tương ứng. Backend lưu tạm tệp đầu vào, chuyển dữ liệu đến pipeline được lựa chọn và nhận lại kết quả suy luận.

Bảng 3.1 Các thành phần của hệ thống

Thành phần	Công nghệ	Chức năng
Frontend	React, Vite	Giao diện người dùng, tải ảnh/video và hiển thị kết quả
Backend API	Flask	Tiếp nhận yêu cầu và điều phối suy luận
Inference Service	PyTorch, Ultralytics	Nạp mô hình và thực hiện nhận diện
Luồng kiểm thử 1	YOLOv8n	Phát hiện và phân loại biển báo trong một lần suy luận
Luồng kiểm thử 2	YOLOv8n + EfficientNet-B0	Phát hiện bằng YOLO và phân loại bằng CNN
OpenCV	OpenCV	Tiền xử lý ảnh và video

Thành phần	Công nghệ	Chức năng
Model Storage	Artifacts	Lưu trữ trọng số mô hình và cấu hình triển khai

Đối với dữ liệu video, hệ thống xử lý lần lượt từng khung hình. Quá trình theo dõi đối tượng được thực hiện nhằm duy trì định danh biển báo giữa các frame liên tiếp. Cơ chế này giúp hạn chế việc thực hiện phân loại lặp lại nhiều lần đối với cùng một đối tượng, từ đó cải thiện hiệu năng xử lý của hệ thống.

Để phục vụ giao tiếp giữa giao diện Web và máy chủ, hệ thống xây dựng tập các REST API như trình bày trong bảng.

Bảng 3.2 Các API chính của hệ thống

Endpoint	Phương thức	Chức năng
/health	GET	Kiểm tra trạng thái hệ thống và mô hình đang được nạp
/predict/flow1	POST	Nhận diện ảnh bằng Pipeline 1 (YOLO End-to-End)
/predict/flow2	POST	Nhận diện ảnh bằng Pipeline 2 (YOLO + CNN)
/predict/video/flow1	POST	Nhận diện video bằng Pipeline 1
/predict/video/flow2	POST	Nhận diện video bằng Pipeline 2

Endpoint	Phương thức	Chức năng
/outputs/<filename>	GET	Truy xuất video đã được xử lý
/	GET	Truy cập giao diện Web của hệ thống

Kiến trúc triển khai được thiết kế theo hướng mô-đun hóa nhằm phục vụ mục tiêu nghiên cứu và đánh giá hai luồng kiểm thử nhận diện biển báo giao thông.


3.5.2. Giao diện người dùng

Hệ thống cung cấp hai chế độ làm việc chính gồm nhận diện trên ảnh tĩnh và nhận diện trên video. Người dùng chỉ cần tải dữ liệu đầu vào lên hệ thống và thực hiện suy luận mà không cần các thao tác cấu hình phức tạp.


Đối với chế độ nhận diện ảnh, hệ thống cho phép tải lên một ảnh chứa biển báo giao thông và thực hiện đồng thời cả hai pipeline trên cùng một dữ liệu đầu vào. Kết quả trả về bao gồm số lượng biển báo được phát hiện, thời gian suy luận, danh sách các biển báo nhận dạng được cùng mức độ tin cậy tương ứng. Bên cạnh đó, ảnh đầu ra được hiển thị trực tiếp với các khung giới hạn và nhãn phân loại để người dùng dễ dàng quan sát kết quả nhận diện.

Hệ thống Nhận dạng Biển báo Giao thông Việt Nam

So sánh hiệu năng giữa pipeline YOLO end-to-end và pipeline lai YOLO + CNN trên tập 52 lớp biển báo.



Hình 3.11 Giao diện tính năng nhận diện




Hình 3.12 Giao diện nhận diện ảnh tĩnh

Đối với chế độ nhận diện video, hệ thống hỗ trợ tải lên các tệp video giao thông và thực hiện xử lý toàn bộ chuỗi khung hình. Sau khi quá trình suy luận hoàn tất, hệ

thống hiển thị các thông tin thống kê như số lượng khung hình đã xử lý, số lượng biển báo phát hiện được, tổng thời gian xử lý và tốc độ xử lý trung bình. Đồng thời, danh sách các biển báo được ghi nhận kèm theo thời điểm xuất hiện trong video cũng được cung cấp nhằm hỗ trợ việc đánh giá kết quả.



Hình 3.13 Giao diện tính năng nhận diện



Hình 3.14 Kết quả nhận diện trên video

Để phục vụ mục tiêu nghiên cứu, giao diện được thiết kế theo hướng so sánh trực quan giữa hai pipeline. Kết quả của luồng kiểm thử 1 và luồng kiểm thử 2 được hiển thị song song trên cùng màn hình với các chỉ số đánh giá và dữ liệu đầu ra tương ứng. Cách trình bày này giúp người dùng dễ dàng đối chiếu sự khác biệt về tốc độ xử lý, số lượng đối tượng phát hiện, độ tin cậy dự đoán và chất lượng nhận diện giữa hai hướng tiếp cận.

Nhìn chung giao diện Web đóng vai trò là cầu nối giữa người dùng và các mô hình học sâu, đồng thời là công cụ hỗ trợ trực quan cho quá trình đánh giá và so sánh hiệu năng của các pipeline nhận diện biển báo giao thông được đề xuất trong đề tài.

KẾT LUẬN VÀ KIẾN NGHỊ

1. Kết quả đạt được

Đề tài này đã nghiên cứu và xây dựng thành công hệ thống nhận diện và phân loại biển báo giao thông Việt Nam sử dụng Deep Learning. Bao gồm quá trình xử lý dữ liệu, huấn luyện mô hình, đánh giá và triển khai hệ thống web phục vụ mục đích kiểm thử thực tế.

Đối với tính năng phát hiện đối tượng, ba kiến trúc YOLO bao gồm YOLOv5n, YOLOv8n và YOLOv11n cho thấy YOLOv8n đạt sự hiệu quả tốt nhất giữa độ chính xác và tốc độ xử lý. Mô hình không chỉ đạt giá trị $mAP@0.5:0.95$ cao nhất mà còn có tốc độ suy luận cao, phù hợp với dự đoán thời gian thực. Thí nghiệm cũng cho thấy kỹ thuật Mosaic Data Augmentation mang lại tác động tích cực đối với chất lượng phát hiện, góp phần cải thiện khả năng bao phủ đối tượng của mô hình.

Trong nhóm mô hình phân loại ảnh thì ResNet50 và EfficientNet-B0 được đánh giá qua nhiều loại cấu hình huấn luyện khác nhau nhau. Kết quả cho thấy EfficientNet-B0 đạt hiệu năng phân loại cao hơn dựa trên chỉ số Accuracy và F1-score, đồng thời có kích thước mô hình nhỏ. Việc dùng Transfer Learning và lựa chọn learning rate phù hợp giúp các mô hình tận dụng hiệu quả từ bộ dữ liệu lớn, từ đó nâng cao khả năng nhận diện trên tập biển báo giao thông Việt Nam.

Dựa trên các mô hình được chọn, nghiên cứu xây dựng hai hướng kiểm thử khác nhau. Hướng kiểm thử thứ nhất sử dụng YOLO theo hướng end-to-end để thực hiện đồng thời phát hiện và phân loại biển báo. Hướng tiếp cận thứ 2 kết hợp cả mô hình YOLO và CNN nhằm tăng cường khả năng nhận dạng. Kết quả từ nghiên cứu cho thấy hướng tiếp cận thứ nhất đạt hiệu quả cao nhất với thời gian chạy tốt nhất.

Bên cạnh phần nghiên cứu mô hình đề tài cũng đã triển khai thành công hệ thống Web cho phép người dùng thực hiện nhận diện biển báo trên ảnh và video. Hệ thống hoạt động ổn định, cung cấp kết quả trực quan và đáp ứng được mục tiêu ứng dụng thực tế của đề tài. Những kết quả đạt được cho thấy tính khả thi của việc ứng dụng Deep

Learning vào bài toán nhận diện biển báo giao thông Việt Nam, đồng thời tạo nền tảng cho các nghiên cứu mở rộng trong tương lai.

2. Hạn chế

Mặc dù đạt được các mục tiêu đề ra, nghiên cứu vẫn còn tồn tại một số hạn chế nhất định. Trước hết, các mô hình Deep Learning được sử dụng trong nghiên cứu đều mang tính hộp đen, khiến quá trình giải thích cơ sở đưa ra dự đoán của mô hình còn nhiều hạn chế. Điều này gây khó khăn trong việc phân tích nguyên nhân của các trường hợp nhận diện hoặc phân loại sai, đồng thời làm giảm tính minh bạch và khả năng giải thích của hệ thống khi triển khai trong các ứng dụng thực tế

Các thí nghiệm chủ yếu được thực hiện trên dữ liệu ảnh và video đã được thu thập, chưa đánh giá đầy đủ trong các điều kiện môi trường phức tạp như thời tiết xấu, ánh sáng yếu, biển báo bị che khuất hoặc xuất hiện ở khoảng cách rất xa. Do đó, hiệu năng của hệ thống trong các bối cảnh thực tế đặc biệt vẫn cần được kiểm chứng thêm.

Đề tài tập trung vào các phiên bản mô hình có kích thước nhỏ nhằm đảm bảo tốc độ suy luận và khả năng triển khai trên phần cứng phổ thông. Vì vậy, các kiến trúc có độ phức tạp cao hơn hoặc các phương pháp tiên tiến mới xuất hiện chưa được đưa vào phạm vi khảo sát và so sánh.

Mặt khác hệ thống Web hiện tại mới đóng vai trò như một nền tảng trình diễn và kiểm thử chức năng. Các nội dung liên quan đến tối ưu hóa hạ tầng, khả năng mở rộng, bảo mật hệ thống và triển khai trên môi trường sản xuất chưa được nghiên cứu chuyên sâu.

3. Hướng phát triển

Trong thời gian tới, nghiên cứu có thể được mở rộng theo nhiều hướng nhằm nâng cao chất lượng nhận diện cũng như khả năng ứng dụng thực tiễn của hệ thống.

Một hướng phát triển quan trọng là mở rộng và cập nhật bộ dữ liệu với số lượng mẫu lớn hơn, bao phủ nhiều điều kiện môi trường khác nhau như ban đêm, mưa, sương mù

hoặc các trường hợp biển báo bị biến dạng, mờ và che khuất. Việc bổ sung dữ liệu đa dạng sẽ giúp mô hình học được các đặc trưng tổng quát hơn và nâng cao khả năng hoạt động trong thực tế.

Đối với hướng ứng dụng hệ thống có thể được tích hợp với camera giao thông, thiết bị nhúng hoặc các nền tảng hỗ trợ lái xe nhằm xây dựng giải pháp nhận diện biển báo thời gian thực. Việc kết hợp thêm các thành phần như nhận diện làn đường, phát hiện phương tiện và theo dõi đối tượng sẽ tạo điều kiện phát triển các hệ thống giao thông thông minh có tính ứng dụng cao hơn.

Ngoài ra cần thực hiện các thử nghiệm quy mô lớn trong môi trường thực tế nhằm đánh giá toàn diện tính ổn định, độ tin cậy và khả năng đáp ứng của hệ thống trước các tình huống vận hành khác nhau. Đây là bước cần thiết để chuyển đổi từ mô hình nghiên cứu sang các ứng dụng triển khai thực tế.

PHỤ LỤC

1. Mã nguồn và bộ dữ liệu

- Mã nguồn: <https://github.com/AnPD2004/vietnam-traffic-sign-recognition>
- Bộ dữ liệu: <https://www.kaggle.com/datasets/maitam/vietnamese-traffic-signs>

2. Cách chạy mã nguồn

Yêu cầu

- Python 3.12, Node.js ≥ 18 , npm, uv, Git
- RAM ≥ 8 GB (khuyến nghị 16 GB); GPU NVIDIA + CUDA (khuyến nghị khi train)
- Dung lượng ổ cứng trống ≥ 10 GB

Cài đặt

- Clone repo và vào thư mục gốc: `cd vietnam-traffic-sign-recognition`
- Cài backend: `uv sync` (tạo `.venv` và cài PyTorch, Ultralytics, Flask, OpenCV...)
- Cài frontend: `cd fe && npm install && cd ..`
- Kiểm tra GPU (tùy chọn): `uv run python -c "import torch; print(torch.cuda.is_available())"`

Huấn luyện Pipeline 1 (YOLO End-to-End)

- Chạy full benchmark: `uv run python -m src.pipeline1 --device 0`
- Chạy thử nhanh (1 epoch): `uv run python -m src.pipeline1 --test`
- Xem kế hoạch chạy: `uv run python -m src.pipeline1 --dry-run`
- Chạy một thí nghiệm: `uv run python -m src.pipeline1 --experiment exp1_model_compare`
- Train lại dù đã có kết quả: thêm `--force`

Huấn luyện Pipeline 2 (YOLO + CNN)

- **Điều kiện:** Pipeline 1 đã có `artifacts/pipeline1/best/best.json`
- Chạy full benchmark: `uv run python -m src.pipeline2 --skip-crops --device 0`

- Bỏ --skip-crops nếu chưa tạo dataset crop
- Kết quả: artifacts/pipeline2/ (weights .pth, best/best.json, báo cáo tương tự Pipeline 1)

Thứ tự chạy đề xuất

- uv run python -m src.pipeline1 → chọn YOLO tốt nhất
- uv run python -m src.build_crops.build_crops_for_cnn → tạo ảnh crop cho CNN
- uv run python -m src.pipeline2 → chọn CNN tốt nhất
- Chạy web demo (bước dưới)

Chạy ứng dụng Web

- Terminal 1 — Backend: uv run python app.py (port **5000**)
- Terminal 2 — Frontend: cd fe && npm run dev (port **5173**)
- Mở trình duyệt: <http://localhost:5173>

TÀI LIỆU THAM KHẢO

- [1] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Cham, Switzerland: Springer, 2022.
- [2] D. A. Forsyth and J. Ponce, *Computer Vision: A Modern Approach*, 2nd ed. Upper Saddle River, NJ, USA: Pearson, 2011.
- [3] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [4] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015.
- [5] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998.
- [6] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Lake Tahoe, NV, USA, 2012, pp. 1097–1105.
- [7] R. Girshick, “Fast R-CNN,” in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, Santiago, Chile, 2015, pp. 1440–1448.
- [8] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137–1149, Jun. 2017.
- [9] W. Liu et al., “SSD: Single shot multibox detector,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, Amsterdam, The Netherlands, 2016, pp. 21–37.
- [10] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, real-time object detection,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, 2016, pp. 779–788.

- [11] J. Redmon and A. Farhadi, “YOLO9000: Better, faster, stronger,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Honolulu, HI, USA, 2017, pp. 7263–7271.
- [12] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal speed and accuracy of object detection,” arXiv:2004.10934, Apr. 2020.
- [13] C.-Y. Wang, A. Bochkovskiy, and H.-Y. M. Liao, “YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Vancouver, BC, Canada, 2023, pp. 7464–7475.
- [14] G. Jocher et al., Ultralytics YOLO Documentation, 2023. [Online]. Available: <https://docs.ultralytics.com/>. [Accessed: Jun. 8, 2026].
- [15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Las Vegas, NV, USA, 2016, pp. 770–778.
- [16] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in Proc. 36th Int. Conf. Mach. Learn. (ICML), Long Beach, CA, USA, 2019, pp. 6105–6114.
- [17] M. Tan and Q. V. Le, “EfficientNetV2: Smaller models and faster training,” in Proc. 38th Int. Conf. Mach. Learn. (ICML), Virtual Event, 2021, pp. 10096–10106.
- [18] T. Fawcett, “An introduction to ROC analysis,” Pattern Recognit. Lett., vol. 27, no. 8, pp. 861–874, Jun. 2006.
- [19] D. M. W. Powers, “Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation,” J. Mach. Learn. Technol., vol. 2, no. 1, pp. 37–63, 2011.

[20] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The Pascal Visual Object Classes (VOC) challenge,” *Int. J. Comput. Vis.*, vol. 88, no. 2, pp. 303–338, Jun. 2010.



TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH