

CHƯƠNG 1: TỔNG QUAN	4
1.1. Tình hình nghiên cứu	4
1.1.1. Nghiên cứu nhận diện biển báo giao thông trên thế giới.....	4
1.1.2. Tình hình nghiên cứu tại Việt Nam	4
1.1.3. Các hướng tiếp cận hiện nay.....	4
1.2. Lý do chọn đề tài	5
1.3. Mục tiêu, nội dung, phương pháp nghiên cứu đề tài	6
1.3.1. Mục tiêu nghiên cứu.....	6
1.3.2. Nội dung nghiên cứu	6
1.3.3. Phương pháp nghiên cứu	6
1.4. Đối tượng và phạm vi nghiên cứu	7
1.4.1. Đối tượng nghiên cứu	7
1.4.2. Phạm vi nghiên cứu.....	7
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	8
2.1. Convolutional Neural Network (CNN)	8
2.1.1. Khái niệm Convolutional Neural Network.....	8
2.1.2. Cấu trúc cơ bản của CNN	8
2.1.3. Cơ chế học đặc trưng của CNN.....	10
2.1.4. Ứng dụng của CNN trong nhận diện biển báo giao thông.....	11
2.2. Object Detection.....	11
2.2.1. Khái niệm Object Detection	11
2.2.2. Các thành phần của bài toán Object Detection	11
2.2.3. Các hướng tiếp cận trong Object Detection.....	13
2.2.4. Vai trò của Object Detection trong nhận diện biển báo giao thông.....	14
2.3. YOLO.....	14
2.3.1. Tổng quan về YOLO	14
2.3.2. Nguyên lý hoạt động của YOLO	15
2.3.3. Ưu điểm và hạn chế của YOLO	16

2.4.5. Vai trò của YOLO trong bài toán nhận diện biển báo giao thông	16
2.4. ResNet và EfficientNet.....	16
2.4.1. Tổng quan về các mô hình CNN hiện đại	16
2.4.2. ResNet	17
2.4.3. EfficientNet	18
2.4.4. So sánh ResNet và EfficientNet	19
2.4.5. Vai trò của ResNet và EfficientNet trong đề tài	20
2.5. Chỉ số đánh giá mô hình.....	20
2.5.1. Precision	21
2.5.2. Recall	21
2.5.3. F1-score	22
2.5.4. Accuracy	22
2.5.5. Intersection over Union (IoU)	23
2.5.6. Mean Average Precision (mAP)	23
2.5.7. Confusion Matrix	24
2.5.8. Tốc độ suy luận và kích thước mô hình	24
CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG	25
3.1. Dữ liệu nghiên cứu	25
3.1.1. Tổng quan.....	25
3.1.2. Thống kê bộ dữ liệu	25
3.2. Quy trình xử lý dữ liệu	25
3.2.1. Chuẩn hóa dữ liệu cho YOLO	25
3.2.2. Xây dựng tập dữ liệu Classification cho CNN	25
3.3. Thiết kế hệ thống	25
3.3.1. Kiến trúc tổng thể hệ thống	25
3.3.2. Pipeline 1: YOLO End-to-End	26
3.3.3. Pipeline 2: YOLO kết hợp CNN	27
3.4. Xây dựng mô hình YOLO.....	28
3.4.1. Các mô hình YOLO sử dụng	28

3.4.2. Data Augmentation trong huấn luyện YOLO	28
3.4.3. Cấu hình huấn luyện YOLO	29
3.5. Xây dựng mô hình CNN.....	31
3.5.1. ResNet50	31
3.5.2. EfficientNet-B0	31
3.5.3. Cấu hình huấn luyện	32
CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ.....	34
4.1. Môi trường và kịch bản thực nghiệm	34
4.2. Kết quả thực nghiệm YOLO	36
4.2.1. So sánh các mô hình YOLO	36
4.2.2. Phân tích ảnh hưởng Hyperparameter	36
4.2.3. Lựa chọn mô hình YOLO tốt nhất.....	36
4.3. Kết quả thực nghiệm CNN.....	36
4.3.1. So sánh ResNet50 và EfficientNet-B0	36
4.3.2. Phân tích Hyperparameter	36
4.3.3. Lựa chọn mô hình CNN tốt nhất	36
4.4. Đánh giá hai Pipeline	36
4.4.1. Pipeline YOLO End-to-End	36
4.4.2. Pipeline YOLO kết hợp CNN	36
4.4.3. So sánh và thảo luận	36
4.5. Triển khai hệ thống Web	36
4.5.1. Kiến trúc hệ thống	36
4.5.2. Giao diện người dùng	36
4.5.3. Kết quả kiểm thử.....	36
KẾT LUẬN VÀ KIẾN NGHỊ.....	36
1. Kết luận	36
2. Hạn chế	36
3. Kiến nghị	36
TÀI LIỆU THAM KHẢO.....	37

CHƯƠNG 1: TỔNG QUAN

1.1. Tình hình nghiên cứu

1.1.1. Nghiên cứu nhận diện biển báo giao thông trên thế giới

Nhận diện và phân loại biển báo giao thông là một trong những bài toán quan trọng thuộc lĩnh vực thị giác máy tính, đồng thời giữ vai trò nền tảng trong các hệ thống giao thông thông minh, hệ thống hỗ trợ lái xe nâng cao và phương tiện tự hành. Mục tiêu của bài toán là xác định vị trí xuất hiện của biển báo trong ảnh hoặc video, sau đó nhận dạng chính xác loại biển báo tương ứng để hỗ trợ quá trình ra quyết định của hệ thống.

Sự phát triển của Deep Learning đã tạo ra bước chuyển đáng kể trong lĩnh vực nhận diện đối tượng nói chung và nhận diện biển báo giao thông nói riêng. Nhiều kiến trúc phát hiện đối tượng hiện đại như Faster R-CNN, SSD và YOLO đã được áp dụng rộng rãi cho bài toán nhận diện biển báo giao thông. Trong đó, YOLO và các kiến trúc CNN như ResNet và EfficientNet nhận được nhiều sự quan tâm nhờ khả năng xử lý theo thời gian thực cùng hiệu quả cân bằng giữa tốc độ và độ chính xác.

1.1.2. Tình hình nghiên cứu tại Việt Nam

Tại Việt Nam, Phần lớn các nghiên cứu hiện nay tập trung vào việc sử dụng một mô hình duy nhất để thực hiện đồng thời phát hiện và phân loại đối tượng. Mặc dù cách tiếp cận này giúp đơn giản hóa kiến trúc hệ thống và giảm thời gian suy luận, khả năng phân biệt giữa các lớp biển báo có mức độ tương đồng cao đôi khi vẫn còn hạn chế. Vì vậy, xu hướng kết hợp giữa mô hình phát hiện đối tượng và mô hình phân loại chuyên biệt đang được quan tâm nhằm khai thác ưu điểm của từng thành phần trong hệ thống.

1.1.3. Các hướng tiếp cận hiện nay

Đối với bài toán nhận diện biển báo giao thông, hiện nay tồn tại hai hướng tiếp cận phổ biến.

Hướng tiếp cận thứ nhất sử dụng mô hình phát hiện đối tượng theo dạng end-to-end. Trong phương pháp này, mô hình nhận ảnh đầu vào và trực tiếp đưa ra vị trí cũng

như nhãn của biển báo trong một lần suy luận. Cách tiếp cận này có ưu điểm về tốc độ xử lý, kiến trúc đơn giản và thuận lợi cho các ứng dụng yêu cầu thời gian thực. YOLO là một trong những đại diện tiêu biểu của nhóm phương pháp này.

Hướng tiếp cận thứ hai tách riêng quá trình phát hiện và phân loại thành hai giai đoạn độc lập. Trước tiên, mô hình phát hiện đối tượng được sử dụng để xác định vị trí biển báo. Sau đó, vùng ảnh chứa biển báo được cắt ra và đưa vào mô hình CNN để thực hiện phân loại chi tiết. Việc tách biệt hai nhiệm vụ cho phép mô hình phân loại tập trung khai thác các đặc trưng chuyên sâu của biển báo, từ đó có khả năng cải thiện kết quả nhận dạng đối với những lớp có mức độ tương đồng cao. Đổi lại, hệ thống sẽ phát sinh thêm chi phí tính toán và thời gian xử lý.

Xuất phát từ những ưu điểm và hạn chế riêng của từng hướng tiếp cận, việc xây dựng và đánh giá đồng thời hai pipeline là cần thiết để có cái nhìn toàn diện hơn về khả năng ứng dụng trong điều kiện thực tế.

1.2. Lý do chọn đề tài

Tai nạn giao thông vẫn là một trong những vấn đề được quan tâm tại nhiều quốc gia, trong đó có Việt Nam. Việc tuân thủ các quy định giao thông phụ thuộc đáng kể vào khả năng nhận biết và xử lý thông tin từ hệ thống biển báo trên đường. Trong bối cảnh các hệ thống hỗ trợ lái xe và phương tiện tự hành đang phát triển mạnh mẽ, nhu cầu xây dựng các giải pháp nhận diện biển báo giao thông có độ chính xác cao và khả năng hoạt động theo thời gian thực ngày càng trở nên cấp thiết.

Từ những lý do trên, đề tài “Xây dựng hệ thống nhận diện và phân loại biển báo giao thông Việt Nam sử dụng Deep Learning” được lựa chọn nhằm nghiên cứu, xây dựng và đánh giá các phương pháp nhận diện biển báo phù hợp với điều kiện dữ liệu và nhu cầu ứng dụng thực tế tại Việt Nam. Nội dung đề tài phù hợp với định hướng phát triển của lĩnh vực thị giác máy tính, đồng thời có khả năng mở rộng cho các hệ thống giao thông thông minh trong tương lai.

1.3. Mục tiêu, nội dung, phương pháp nghiên cứu đề tài

1.3.1. Mục tiêu nghiên cứu

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống có khả năng phát hiện và phân loại biển báo giao thông Việt Nam dựa trên các kỹ thuật Deep Learning, đồng thời đánh giá hiệu quả của các hướng tiếp cận khác nhau đối với bài toán này.

1.3.2. Nội dung nghiên cứu

Nội dung nghiên cứu của đề tài được triển khai theo nhiều giai đoạn liên tiếp nhằm đảm bảo tính hoàn chỉnh của hệ thống.

Trước hết, dữ liệu biển báo giao thông được thu thập, chuẩn hóa và tổ chức theo định dạng phù hợp cho bài toán phát hiện đối tượng. Từ dữ liệu gốc, các vùng ảnh chứa biển báo được tách ra dựa trên thông tin bounding box để xây dựng tập dữ liệu phục vụ cho bài toán phân loại.

Sau quá trình chuẩn bị dữ liệu, đề tài tiến hành huấn luyện mô hình YOLO để thực hiện đồng thời việc phát hiện và phân loại biển báo trên ảnh đầu vào. Song song với đó, một mô hình CNN được xây dựng và huấn luyện trên tập ảnh đã được cắt từ các vùng biển báo nhằm phục vụ nhiệm vụ phân loại chuyên biệt.

1.3.3. Phương pháp nghiên cứu

Đề tài kết hợp giữa phương pháp nghiên cứu lý thuyết và phương pháp thực nghiệm.

Trong giai đoạn nghiên cứu lý thuyết, các tài liệu liên quan đến phát hiện đối tượng, phân loại ảnh và nhận diện biển báo giao thông được khảo sát nhằm xây dựng nền tảng kiến thức cho quá trình triển khai. Những kiến trúc học sâu phổ biến trong lĩnh vực thị giác máy tính được phân tích để lựa chọn mô hình phù hợp với mục tiêu nghiên cứu.

Ở giai đoạn thực nghiệm, dữ liệu được tiền xử lý và chia thành các tập huấn luyện, xác thực và kiểm thử. Các mô hình được huấn luyện trên cùng một nguồn dữ liệu nhằm đảm bảo tính khách quan trong quá trình so sánh. Sau khi hoàn thành huấn luyện, hệ

thống được đánh giá thông qua các chỉ số định lượng và các thử nghiệm trên ảnh, video thực tế để xác định khả năng ứng dụng của từng hướng tiếp cận.

1.4. Đối tượng và phạm vi nghiên cứu

1.4.1. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là các phương pháp và mô hình Deep Learning được sử dụng trong bài toán nhận diện biển báo giao thông Việt Nam. Trọng tâm nghiên cứu tập trung vào các kỹ thuật phát hiện đối tượng và phân loại ảnh nhằm xây dựng hệ thống có khả năng xác định vị trí cũng như nhận dạng chính xác các loại biển báo xuất hiện trong ảnh hoặc video.

Bên cạnh các mô hình học sâu, đề tài cũng nghiên cứu quy trình xây dựng dữ liệu, kỹ thuật tiền xử lý ảnh, phương pháp đánh giá mô hình và các yếu tố ảnh hưởng đến hiệu năng của hệ thống nhận diện biển báo giao thông.

1.4.2. Phạm vi nghiên cứu

Đề tài tập trung xây dựng hệ thống nhận diện và phân loại 52 lớp biển báo giao thông Việt Nam trên dữ liệu ảnh. Hệ thống được phát triển bằng ngôn ngữ Python, sử dụng thư viện PyTorch và framework Ultralytics để triển khai các mô hình học sâu.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Convolutional Neural Network (CNN)


2.1.1. Khái niệm Convolutional Neural Network

Convolutional Neural Network (CNN) là một kiến trúc mạng nơ-ron sâu được thiết kế chuyên biệt cho việc xử lý dữ liệu dạng lưới, đặc biệt là dữ liệu ảnh. Khác với các mạng nơ-ron truyền thống, CNN có khả năng khai thác mối quan hệ không gian giữa các điểm ảnh thông qua các phép tích chập, từ đó học được những đặc trưng có ý nghĩa trực tiếp từ dữ liệu đầu vào mà không cần xây dựng thủ công các bộ mô tả đặc trưng [3], [5].

Đối với dữ liệu hình ảnh, CNN có khả năng tự động học từ các đặc trưng đơn giản như cạnh, góc, đường cong ở các tầng đầu tiên, sau đó dần hình thành các đặc trưng có mức độ trừu tượng cao hơn ở các tầng sâu hơn. Cơ chế này cho phép mô hình nhận diện hiệu quả các đối tượng phức tạp ngay cả khi xuất hiện sự thay đổi về vị trí, tỷ lệ hoặc điều kiện quan sát [3].


2.1.2. Cấu trúc cơ bản của CNN

Một mô hình CNN thường được xây dựng từ nhiều loại tầng khác nhau, trong đó ba thành phần quan trọng nhất gồm tầng tích chập, tầng gộp và tầng kết nối đầy đủ.



Hình 2.1. Kiến trúc cơ bản của mạng Convolutional Neural Network (CNN)

Tầng tích chập (Convolution Layer) đóng vai trò trích xuất đặc trưng từ ảnh đầu vào. Tại mỗi vị trí, một bộ lọc kích thước nhỏ được trượt trên ảnh để thực hiện phép tích chập, tạo ra các bản đồ đặc trưng (feature maps). Mỗi bộ lọc sẽ học cách phát hiện một loại đặc trưng nhất định, chẳng hạn như cạnh ngang, cạnh dọc hoặc các mẫu hình học phức tạp hơn [3].



Hình 2.2. Minh họa quá trình tích chập trong CNN


Sau quá trình tích chập, hàm kích hoạt phi tuyến thường được áp dụng nhằm tăng khả năng biểu diễn của mạng. Trong các kiến trúc hiện đại, hàm Rectified Linear Unit (ReLU) được sử dụng phổ biến nhờ khả năng giảm hiện tượng mất gradient và cải thiện tốc độ hội tụ trong quá trình huấn luyện [6].

Tầng gộp (Pooling Layer) được sử dụng để giảm kích thước không gian của các bản đồ đặc trưng. Quá trình này giúp giảm số lượng tham số cần học, hạn chế hiện tượng quá khớp và tăng khả năng khái quát hóa của mô hình. Trong thực tế, Max Pooling là phương pháp được sử dụng rộng rãi nhất do khả năng giữ lại những đặc trưng nổi bật trong vùng quan sát [3].

Ở các tầng cuối, đặc trưng đã được trích xuất sẽ được đưa vào các tầng kết nối đầy đủ (Fully Connected Layer) để thực hiện quá trình phân loại. Đầu ra cuối cùng thường được chuẩn hóa bằng hàm Softmax nhằm tạo ra phân bố xác suất trên các lớp cần dự đoán.

2.1.3. Cơ chế học đặc trưng của CNN

Một trong những ưu điểm quan trọng nhất của CNN là khả năng học đặc trưng theo cấu trúc phân cấp. Thay vì xử lý toàn bộ ảnh như một vector dữ liệu lớn, CNN tận dụng tính chất cục bộ của ảnh thông qua kết nối thưa và cơ chế chia sẻ trọng số.



Hình 2.3. Cơ chế học đặc trưng phân cấp của CNN

Kết nối thưa (Sparse Connectivity) cho phép mỗi nơ-ron chỉ tương tác với một vùng nhỏ của ảnh đầu vào, còn gọi là trường cảm thụ (receptive field). Điều này giúp giảm đáng kể số lượng tham số so với các mạng kết nối đầy đủ truyền thống [3].

Song song với đó, cơ chế chia sẻ trọng số (Weight Sharing) cho phép cùng một bộ lọc được áp dụng trên toàn bộ ảnh. Nhờ vậy, CNN có khả năng phát hiện cùng một đặc trưng tại nhiều vị trí khác nhau mà không cần học lại nhiều lần. Đây là yếu tố quan trọng giúp mô hình đạt hiệu quả cao trong các bài toán nhận dạng hình ảnh [5].

Khi số lượng tầng tăng lên, CNN dần học được các biểu diễn phức tạp hơn. Những tầng gần đầu vào thường nhận biết các đặc trưng cơ bản như cạnh hoặc màu sắc, trong khi các tầng sâu hơn có thể mô tả các cấu trúc đặc trưng của đối tượng. Đối với bài toán

nhận diện biển báo giao thông, quá trình này giúp mô hình phân biệt được những biển báo có hình dạng hoặc màu sắc tương đồng nhưng khác nhau ở các chi tiết nhỏ.

2.1.4. Ứng dụng của CNN trong nhận diện biển báo giao thông

Đối với những hệ thống nhận diện biển báo theo hướng hai giai đoạn, CNN thường được sử dụng sau bước phát hiện đối tượng. Sau khi vùng chứa biển báo được xác định bởi bộ phát hiện, ảnh biển báo sẽ được cắt ra và đưa vào mạng CNN để thực hiện phân loại chi tiết. Cách tiếp cận này giúp mô hình tập trung hoàn toàn vào thông tin của biển báo thay vì phải xử lý toàn bộ khung hình.

Trong phạm vi đề tài, CNN được sử dụng ở pipeline kết hợp giữa bộ phát hiện đối tượng và bộ phân loại ảnh. Sau khi mô hình YOLO xác định vị trí biển báo, vùng ảnh tương ứng sẽ được trích xuất và đưa vào CNN để dự đoán lớp cuối cùng. Hai kiến trúc được nghiên cứu là ResNet và EfficientNet, đây đều là những mô hình đã chứng minh hiệu quả cao trong các nhiệm vụ phân loại ảnh hiện đại [15]–[17].

2.2. Object Detection

2.2.1. Khái niệm Object Detection

Object Detection là bài toán xác định vị trí và phân loại các đối tượng xuất hiện trong ảnh hoặc video. Khác với Image Classification chỉ đưa ra nhãn cho toàn bộ ảnh, Object Detection yêu cầu hệ thống đồng thời trả lời hai câu hỏi: đối tượng nằm ở đâu và đối tượng đó thuộc lớp nào [1], [2].

Kết quả của một mô hình Object Detection thường bao gồm các khung giới hạn (bounding box), nhãn lớp và độ tin cậy tương ứng. Mỗi bounding box được biểu diễn bằng tọa độ xác định vùng chứa đối tượng trong ảnh, trong khi nhãn lớp mô tả loại đối tượng được phát hiện.

2.2.2. Các thành phần của bài toán Object Detection

Một hệ thống phát hiện đối tượng hiện đại thường bao gồm ba nhiệm vụ chính: trích xuất đặc trưng, định vị đối tượng và phân loại đối tượng.

Giai đoạn đầu tiên là trích xuất đặc trưng từ ảnh đầu vào. Các mạng CNN hoặc các backbone hiện đại được sử dụng để chuyển đổi dữ liệu ảnh thành các biểu diễn đặc trưng giàu thông tin. Những đặc trưng này đóng vai trò nền tảng cho các bước xử lý tiếp theo [7].

Tiếp theo là nhiệm vụ định vị đối tượng (Localization). Mục tiêu của giai đoạn này là xác định vị trí xuất hiện của đối tượng thông qua các bounding box. Độ chính xác của bounding box ảnh hưởng trực tiếp đến hiệu quả của toàn bộ hệ thống phát hiện.



Hình 2.4. Các thành phần của Object Detection


Cuối cùng, hệ thống thực hiện phân loại đối tượng bằng cách dự đoán lớp tương ứng cho từng vùng được phát hiện. Đầu ra thường bao gồm xác suất thuộc về từng lớp và giá trị confidence phản ánh mức độ tin cậy của dự đoán.

Trong quá trình suy luận, nhiều bounding box có thể cùng bao phủ một đối tượng. Để loại bỏ các dự đoán dư thừa, kỹ thuật Non-Maximum Suppression (NMS) thường được áp dụng nhằm giữ lại những dự đoán có độ tin cậy cao nhất và loại bỏ các khung chồng lấn không cần thiết [1].

2.2.3. Các hướng tiếp cận trong Object Detection

Các phương pháp phát hiện đối tượng hiện đại thường được chia thành hai nhóm chính là two-stage detector và single-stage detector.

Nhóm two-stage detector thực hiện phát hiện đối tượng qua hai bước riêng biệt. Trước tiên, hệ thống sinh ra các vùng ứng viên có khả năng chứa đối tượng. Sau đó, từng vùng ứng viên được phân loại và tinh chỉnh lại vị trí bounding box. Các mô hình tiêu biểu của hướng tiếp cận này bao gồm Fast R-CNN và Faster R-CNN [7], [8].



Hình 2.5. So sánh hai hướng tiếp cận trong Object Detection.

Ưu điểm của các mô hình hai giai đoạn là độ chính xác cao nhờ quá trình xử lý chi tiết trên từng vùng ứng viên. Tuy nhiên, việc thực hiện nhiều bước liên tiếp làm gia tăng chi phí tính toán và giảm tốc độ suy luận, khiến chúng gặp hạn chế trong các ứng dụng yêu cầu thời gian thực.

Nhóm single-stage detector loại bỏ bước sinh vùng ứng viên riêng biệt và thực hiện trực tiếp việc định vị cũng như phân loại đối tượng trên toàn bộ ảnh trong một lần suy luận. SSD và YOLO là những đại diện tiêu biểu của hướng tiếp cận này [9], [10].

Nhờ kiến trúc đơn giản hơn, các mô hình single-stage đạt tốc độ xử lý cao hơn đáng kể so với các phương pháp hai giai đoạn. Điều này đặc biệt quan trọng đối với các

hệ thống cần phản hồi nhanh như camera giao thông, phương tiện tự hành hoặc các ứng dụng giám sát thời gian thực.

2.2.4. Vai trò của Object Detection trong nhận diện biển báo giao thông

Trong bài toán nhận diện biển báo giao thông, bước phát hiện đối tượng đóng vai trò nền tảng của toàn bộ hệ thống. Trước khi tiến hành phân loại, hệ thống cần xác định chính xác vị trí xuất hiện của biển báo trong ảnh. Nếu quá trình phát hiện không chính xác, chất lượng của bước nhận dạng phía sau cũng sẽ bị ảnh hưởng đáng kể.

Nhiều mô hình Object Detection hiện đại như Faster R-CNN, SSD và YOLO đã được áp dụng thành công cho bài toán nhận diện biển báo giao thông [8]–[12]. Trong số đó, YOLO được đánh giá cao nhờ khả năng cân bằng giữa tốc độ và độ chính xác, phù hợp với các ứng dụng yêu cầu xử lý theo thời gian thực.

2.3. YOLO

2.3.1. Tổng quan về YOLO

YOLO (You Only Look Once) là họ mô hình phát hiện đối tượng thuộc nhóm single-stage detector, được giới thiệu lần đầu bởi Redmon và cộng sự vào năm 2016 [10]. Khác với các phương pháp two-stage detector như Fast R-CNN hay Faster R-CNN, YOLO thực hiện đồng thời nhiệm vụ định vị và phân loại đối tượng trong một lần suy luận duy nhất. Cách tiếp cận này giúp giảm đáng kể độ phức tạp tính toán và nâng cao tốc độ xử lý, đặc biệt phù hợp với các ứng dụng yêu cầu phản hồi theo thời gian thực [7], [8], [10].

Ý tưởng cốt lõi của YOLO là xem bài toán phát hiện đối tượng như một bài toán hồi quy trực tiếp từ ảnh đầu vào đến tọa độ bounding box và xác suất lớp. Thay vì tạo ra các vùng đề xuất (region proposals) rồi tiến hành phân loại riêng biệt, toàn bộ ảnh được đưa qua một mạng nơ-ron duy nhất để dự đoán trực tiếp các đối tượng xuất hiện trong ảnh [10].


Nhờ khả năng xử lý nhanh và kiến trúc đơn giản, YOLO đã trở thành một trong những hướng nghiên cứu phổ biến nhất trong lĩnh vực Object Detection. Qua nhiều thế

hệ phát triển, họ mô hình YOLO liên tục được cải tiến nhằm nâng cao độ chính xác, khả năng phát hiện vật thể nhỏ và hiệu quả suy luận trên các thiết bị có tài nguyên hạn chế [11]–[14].

2.3.2. Nguyên lý hoạt động của YOLO

Trong kiến trúc YOLO, ảnh đầu vào được chia thành nhiều vùng không gian. Đối với mỗi vùng, mô hình dự đoán một tập các bounding box cùng với độ tin cậy và xác suất thuộc về các lớp đối tượng khác nhau [10].

Quá trình suy luận của YOLO có thể được mô tả qua ba bước chính. Trước tiên, ảnh được đưa vào mạng CNN để trích xuất đặc trưng. Các đặc trưng này sau đó được sử dụng để dự đoán vị trí bounding box và xác suất lớp tương ứng. Cuối cùng, kỹ thuật Non-Maximum Suppression (NMS) được áp dụng nhằm loại bỏ các dự đoán chồng lấn và giữ lại những kết quả có độ tin cậy cao nhất [1], [10].



Hình 2.6. Nguyên lý hoạt động của YOLO

Đối với mỗi đối tượng được phát hiện, mô hình thường trả về ba thành phần chính gồm tọa độ bounding box, xác suất lớp và giá trị confidence. Confidence phản ánh mức độ chắc chắn của mô hình về việc một đối tượng thực sự tồn tại bên trong bounding box được dự đoán. Những dự đoán có confidence thấp thường bị loại bỏ trong quá trình hậu xử lý nhằm giảm số lượng dự đoán sai.

Một trong những ưu điểm quan trọng của YOLO là khả năng khai thác thông tin toàn cục của ảnh. Do toàn bộ ảnh được xử lý đồng thời thay vì từng vùng riêng lẻ, mô hình có thể tận dụng ngữ cảnh xung quanh đối tượng để cải thiện khả năng nhận dạng [10].

2.3.3. Ưu điểm và hạn chế của YOLO

Ưu điểm nổi bật nhất của YOLO là tốc độ suy luận cao. Nhờ thực hiện đồng thời quá trình định vị và phân loại trong một mạng duy nhất, mô hình có thể xử lý ảnh hoặc video với tốc độ đủ nhanh cho các hệ thống thời gian thực như camera giao thông, robot hoặc phương tiện tự hành [10], [12].

Tuy nhiên, YOLO vẫn tồn tại một số hạn chế. Độ chính xác của mô hình có thể suy giảm khi xử lý các đối tượng rất nhỏ hoặc các lớp có mức độ tương đồng cao. Trong những trường hợp yêu cầu phân biệt các chi tiết tinh vi, việc sử dụng thêm một bộ phân loại chuyên biệt có thể mang lại kết quả tốt hơn. Ngoài ra, hiệu năng của YOLO phụ thuộc đáng kể vào chất lượng dữ liệu huấn luyện cũng như chiến lược tăng cường dữ liệu được áp dụng [12], [13].

2.4.5. Vai trò của YOLO trong bài toán nhận diện biển báo giao thông

YOLO được sử dụng rộng rãi trong các hệ thống nhận diện biển báo giao thông nhờ khả năng phát hiện nhanh các đối tượng có kích thước nhỏ trong môi trường phức tạp. Trong điều kiện thực tế, biển báo thường xuất hiện ở khoảng cách xa, chịu ảnh hưởng của ánh sáng, thời tiết hoặc hiện tượng che khuất. Những yếu tố này đòi hỏi mô hình phải vừa đảm bảo độ chính xác vừa duy trì tốc độ xử lý đủ cao để đáp ứng yêu cầu thời gian thực.

2.4. ResNet và EfficientNet

2.4.1. Tổng quan về các mô hình CNN hiện đại

Sự gia tăng độ sâu của mạng CNN đã góp phần đáng kể vào việc cải thiện khả năng học đặc trưng và độ chính xác trên các bài toán nhận dạng ảnh. Tuy nhiên, khi số lượng tầng ngày càng lớn, quá trình huấn luyện thường gặp phải nhiều vấn đề như mất


gradient, bùng nổ gradient hoặc suy giảm hiệu năng dù kiến trúc trở nên phức tạp hơn [15].

Để giải quyết những hạn chế này, nhiều kiến trúc CNN hiện đại đã được đề xuất với mục tiêu nâng cao khả năng biểu diễn trong khi vẫn đảm bảo hiệu quả tính toán. Trong số đó, ResNet và EfficientNet là hai họ mô hình có ảnh hưởng lớn trong lĩnh vực phân loại ảnh và thường được sử dụng làm backbone hoặc classifier trong các hệ thống Computer Vision hiện đại [15]–[17].

2.4.2. ResNet

ResNet (Residual Network) được đề xuất bởi He và cộng sự vào năm 2016 nhằm giải quyết hiện tượng suy giảm hiệu năng khi tăng độ sâu của mạng nơ-ron [15]. Điểm khác biệt quan trọng của ResNet nằm ở việc sử dụng cơ chế kết nối tắt (skip connection) hay còn gọi là residual connection.

Trong kiến trúc CNN truyền thống, mỗi tầng phải học trực tiếp ánh xạ từ đầu vào sang đầu ra. ResNet thay đổi cách tiếp cận bằng việc yêu cầu mạng học phần dư (residual mapping) giữa đầu vào và đầu ra. Thông tin từ các tầng trước được truyền trực tiếp đến các tầng sau thông qua các kết nối tắt, giúp tín hiệu gradient lan truyền hiệu quả hơn trong quá trình huấn luyện [15].



Hình 2.7. Kiến trúc mạng ResNet với cơ chế Residual Learning và Skip Connection

Về mặt toán học, đầu ra của một residual block được xác định bằng tổng của đầu vào và hàm biến đổi được học bởi các tầng bên trong khối. Cơ chế này giúp giảm hiện tượng mất gradient, cho phép xây dựng các mạng rất sâu mà vẫn duy trì khả năng hội tụ ổn định.


Nhờ kiến trúc residual, ResNet đạt được kết quả vượt trội trên nhiều bộ dữ liệu chuẩn như ImageNet và nhanh chóng trở thành nền tảng cho nhiều nghiên cứu tiếp theo trong lĩnh vực Computer Vision [15]. Các biến thể phổ biến bao gồm ResNet18, ResNet34, ResNet50, ResNet101 và ResNet152, trong đó số phía sau biểu thị số lượng tầng của mạng.

Đối với bài toán phân loại biển báo giao thông, ResNet có khả năng học hiệu quả các đặc trưng hình học và màu sắc của biển báo. Kiến trúc này đặc biệt phù hợp khi áp dụng Transfer Learning do đã được tiền huấn luyện trên các bộ dữ liệu lớn và có khả năng thích nghi tốt với các tập dữ liệu chuyên biệt.

2.4.3. EfficientNet

Mặc dù việc tăng độ sâu hoặc độ rộng của mạng CNN thường giúp cải thiện hiệu năng, cách mở rộng này không phải lúc nào cũng tối ưu về mặt tài nguyên tính toán. Nhằm giải quyết vấn đề đó, Tan và Le đã đề xuất EfficientNet với chiến lược mở rộng mô hình theo hướng cân bằng giữa chiều sâu, chiều rộng và độ phân giải ảnh đầu vào [16].

Thay vì chỉ tăng một yếu tố riêng lẻ, EfficientNet sử dụng phương pháp Compound Scaling để đồng thời điều chỉnh cả ba thành phần của mạng. Cách tiếp cận này giúp mô hình tận dụng hiệu quả tài nguyên tính toán và đạt độ chính xác cao hơn so với nhiều kiến trúc CNN truyền thống có cùng số lượng tham số [16].



Hình 2.8. Kiến trúc EfficientNet sử dụng Compound Scaling để đồng thời tối ưu chiều sâu, chiều rộng và độ phân giải đầu vào

Kiến trúc nền tảng của EfficientNet được xây dựng dựa trên các khối Mobile Inverted Bottleneck Convolution (MBConv), vốn được thiết kế nhằm giảm chi phí tính toán nhưng vẫn duy trì khả năng biểu diễn đặc trưng mạnh mẽ. Bên cạnh đó, cơ chế Squeeze-and-Excitation được tích hợp nhằm tăng cường khả năng học mối quan hệ giữa các kênh đặc trưng khác nhau.

Từ mô hình cơ sở EfficientNet-B0, tác giả đã phát triển nhiều biến thể như EfficientNet-B1 đến EfficientNet-B7 bằng cách áp dụng chiến lược Compound Scaling với các hệ số mở rộng khác nhau [16]. Sau đó, EfficientNetV2 tiếp tục được giới thiệu nhằm cải thiện tốc độ huấn luyện và hiệu quả triển khai thực tế thông qua việc tối ưu cấu trúc mạng và chiến lược học biểu diễn [17].

2.4.4. So sánh ResNet và EfficientNet

ResNet và EfficientNet đều là những kiến trúc CNN mạnh mẽ, tuy nhiên mỗi mô hình được xây dựng dựa trên triết lý thiết kế khác nhau.

ResNet tập trung giải quyết vấn đề huấn luyện mạng sâu thông qua residual connection. Kiến trúc này có tính ổn định cao, được hỗ trợ rộng rãi trong nhiều thư viện học sâu và thường được sử dụng làm lựa chọn mặc định trong các bài toán phân loại ảnh [15].

Trong khi đó, EfficientNet hướng tới việc tối ưu hiệu quả sử dụng tài nguyên tính toán. Với số lượng tham số ít hơn, EfficientNet thường đạt độ chính xác tương đương hoặc cao hơn nhiều kiến trúc CNN truyền thống. Điều này đặc biệt hữu ích trong các hệ thống yêu cầu triển khai trên phần cứng có giới hạn về bộ nhớ hoặc năng lực xử lý [16], [17].

Tuy nhiên, EfficientNet thường yêu cầu quá trình tinh chỉnh siêu tham số cẩn thận hơn so với ResNet. Ngược lại, ResNet có kiến trúc đơn giản, ổn định và dễ huấn luyện trên nhiều loại dữ liệu khác nhau.

2.4.5. Vai trò của ResNet và EfficientNet trong đề tài

Trong đề tài nhận diện và phân loại biển báo giao thông Việt Nam, ResNet và EfficientNet được lựa chọn làm các mô hình CNN phục vụ nhiệm vụ phân loại ảnh trong pipeline kết hợp detector–classifier. Sau khi YOLO xác định vị trí biển báo, vùng ảnh chứa đối tượng sẽ được cắt ra và đưa vào bộ phân loại để dự đoán lớp cuối cùng.

Việc lựa chọn hai kiến trúc này cho phép đánh giá ảnh hưởng của thiết kế mạng CNN đến chất lượng nhận dạng biển báo. ResNet đại diện cho hướng tiếp cận sử dụng mạng sâu với residual connection, trong khi EfficientNet đại diện cho hướng tối ưu hóa hiệu quả giữa độ chính xác và chi phí tính toán. Kết quả thực nghiệm sẽ cung cấp cơ sở để so sánh khả năng ứng dụng của từng mô hình trong hệ thống nhận diện biển báo giao thông Việt Nam.

2.5. Chỉ số đánh giá mô hình

Việc đánh giá mô hình là bước quan trọng nhằm xác định mức độ hiệu quả của hệ thống nhận diện và phân loại biển báo giao thông.

Các chỉ số được sử dụng trong nghiên cứu bao gồm Precision, Recall, F1-score, Accuracy, Intersection over Union (IoU), Mean Average Precision (mAP), Confusion Matrix và tốc độ suy luận. Đây là những thước đo được sử dụng rộng rãi trong các bài toán Computer Vision hiện đại, đặc biệt là Object Detection và Image Classification [18]–[20].

2.5.1. Precision

Precision phản ánh mức độ chính xác của các dự đoán dương tính mà mô hình đưa ra. Chỉ số này cho biết trong số các đối tượng được mô hình nhận diện là đúng lớp hoặc đúng đối tượng, có bao nhiêu dự đoán thực sự chính xác [19].

Precision được tính theo công thức:

$$Precision = \frac{TP}{TP + FP}$$

Trong đó:

- TP (True Positive) là số lượng mẫu được dự đoán đúng.
- FP (False Positive) là số lượng mẫu được dự đoán sai nhưng vẫn được mô hình nhận diện là đúng.

Giá trị Precision càng cao cho thấy số lượng dự đoán sai của mô hình càng thấp. Đối với bài toán nhận diện biển báo giao thông, Precision cao giúp hạn chế tình trạng hệ thống nhận diện nhầm biển báo hoặc phát hiện các đối tượng không phải biển báo.

2.5.2. Recall

Recall đánh giá khả năng tìm kiếm đầy đủ các đối tượng thực sự tồn tại trong dữ liệu. Chỉ số này phản ánh tỷ lệ các đối tượng thực tế được mô hình phát hiện thành công [19].

Recall được xác định như sau:

$$Recall = \frac{TP}{TP + FN}$$

Trong đó:

- FN (False Negative) là số lượng đối tượng thực tế nhưng không được mô hình phát hiện.

Recall có ý nghĩa đặc biệt quan trọng trong các hệ thống hỗ trợ lái xe, bởi việc bỏ sót một biển báo giao thông có thể dẫn đến những quyết định không chính xác trong quá trình vận hành phương tiện.

2.5.3. F1-score

Trong thực tế, Precision và Recall thường tồn tại sự đánh đổi nhất định. Một mô hình có Precision cao chưa chắc đã đạt Recall cao và ngược lại. Vì vậy, F1-score được sử dụng để đánh giá cân bằng giữa hai chỉ số này [19].

F1-score được tính bằng trung bình điều hòa của Precision và Recall:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Giá trị F1-score càng cao chứng tỏ mô hình duy trì được sự cân bằng tốt giữa khả năng phát hiện đầy đủ đối tượng và khả năng hạn chế các dự đoán sai. Trong nghiên cứu này, F1-score được sử dụng để đánh giá cả mô hình phân loại CNN và kết quả phát hiện của YOLO.

2.5.4. Accuracy

Accuracy là tỷ lệ số mẫu được phân loại chính xác trên tổng số mẫu được đánh giá. Đây là chỉ số phổ biến trong các bài toán phân loại ảnh [19].

Accuracy được xác định theo công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó TN (True Negative) là số lượng mẫu âm tính được dự đoán chính xác.

Đối với pipeline YOLO kết hợp CNN, Accuracy được sử dụng để đánh giá chất lượng của bộ phân loại trên tập ảnh biển báo đã được cắt từ bounding box. Tuy nhiên, khi dữ liệu giữa các lớp không cân bằng, Accuracy có thể không phản ánh đầy đủ hiệu năng thực tế của mô hình. Vì vậy, chỉ số này luôn được xem xét cùng với Precision, Recall và F1-score.

2.5.5. Intersection over Union (IoU)

Đối với bài toán phát hiện đối tượng, việc dự đoán đúng lớp là chưa đủ mà còn cần xác định chính xác vị trí của đối tượng trong ảnh. Intersection over Union (IoU) là chỉ số đo lường mức độ chồng lấn giữa bounding box dự đoán và bounding box thực tế [20].

IoU được tính bằng tỷ lệ giữa diện tích giao nhau và diện tích hợp của hai vùng:

$$IoU = \frac{Area(B_{pred} \cap B_{gt})}{Area(B_{pred} \cup B_{gt})}$$

Trong đó:

- B_{pred} là bounding box dự đoán.
- B_{gt} là bounding box nhãn thực tế.

Giá trị IoU nằm trong khoảng từ 0 đến 1. IoU càng cao cho thấy vị trí dự đoán càng gần với vị trí thực tế của đối tượng. Trong các bài toán Object Detection, một dự đoán thường được xem là đúng khi giá trị IoU vượt qua một ngưỡng xác định trước, chẳng hạn 0,5 [20].

2.5.6. Mean Average Precision (mAP)

Mean Average Precision là chỉ số đánh giá quan trọng nhất trong các bài toán phát hiện đối tượng hiện đại [20]. Chỉ số này tổng hợp đồng thời khả năng định vị và khả năng phân loại của mô hình.

Đầu tiên, Average Precision (AP) được tính cho từng lớp đối tượng dựa trên đường cong Precision–Recall. Sau đó, giá trị AP của tất cả các lớp được lấy trung bình để tạo thành mAP [18], [20].

Trong các nghiên cứu hiện đại, hai dạng mAP thường được sử dụng:

- $mAP@0.5$: sử dụng ngưỡng IoU bằng 0,5.
- $mAP@0.5:0.95$: trung bình kết quả tại nhiều ngưỡng IoU từ 0,5 đến 0,95.

Trong đó, $mAP@0.5:0.95$ được đánh giá thấp hơn vì yêu cầu mô hình phải dự đoán chính xác vị trí đối tượng ở nhiều mức độ khác nhau. Đây cũng là chỉ số được sử dụng phổ biến trong các phiên bản YOLO hiện đại [12]–[14].

2.5.7. Confusion Matrix

Confusion Matrix là công cụ trực quan giúp phân tích chi tiết kết quả phân loại của mô hình. Ma trận này thể hiện mối quan hệ giữa nhãn thực tế và nhãn dự đoán, từ đó cho phép xác định những lớp thường bị nhầm lẫn với nhau [19].

2.5.8. Tốc độ suy luận và kích thước mô hình

Bên cạnh độ chính xác, khả năng triển khai thực tế của hệ thống còn phụ thuộc vào hiệu năng suy luận. Đối với các ứng dụng giao thông thông minh và hỗ trợ lái xe, hệ thống cần đưa ra kết quả trong thời gian ngắn để đáp ứng yêu cầu xử lý thời gian thực.

Một số chỉ số được sử dụng gồm:

- Thời gian suy luận trung bình trên mỗi ảnh (Inference Time).
- Số khung hình xử lý trong một giây (Frames Per Second – FPS).
- Kích thước mô hình lưu trữ.
- Mức sử dụng tài nguyên phần cứng trong quá trình suy luận.

CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Dữ liệu nghiên cứu

3.1.1. Tổng quan

3.1.2. Thống kê bộ dữ liệu

3.2. Quy trình xử lý dữ liệu

3.2.1. Chuẩn hóa dữ liệu cho YOLO

3.2.2. Xây dựng tập dữ liệu Classification cho CNN


3.3. Thiết kế hệ thống

3.3.1. Kiến trúc tổng thể hệ thống

Hệ thống nhận diện và phân loại biển báo giao thông Việt Nam được thiết kế theo hướng mô-đun hóa nhằm tạo điều kiện thuận lợi cho quá trình huấn luyện, đánh giá và triển khai thực tế. Kiến trúc tổng thể bao gồm ba thành phần chính: khối chuẩn bị dữ liệu, khối huấn luyện mô hình và khối suy luận (inference).

Quá trình xử lý bắt đầu từ tập dữ liệu gốc chứa ảnh và thông tin bounding box của từng biển báo. Sau bước kiểm tra và chuẩn hóa nhãn, dữ liệu được sử dụng để huấn luyện các mô hình phát hiện đối tượng thuộc họ YOLO. Đồng thời, các vùng ảnh chứa biển báo được cắt ra từ bounding box tương ứng để xây dựng tập dữ liệu phục vụ bài toán phân loại ảnh bằng CNN. Cách tổ chức này cho phép khai thác cùng một nguồn dữ liệu cho hai hướng tiếp cận khác nhau, từ đó đảm bảo tính nhất quán trong quá trình so sánh thực nghiệm.

Đề tài xây dựng hai pipeline nhận diện độc lập. Pipeline thứ nhất sử dụng mô hình YOLO để thực hiện đồng thời nhiệm vụ phát hiện và phân loại biển báo trong một lần suy luận. Pipeline thứ hai áp dụng kiến trúc lai (hybrid), trong đó YOLO đảm nhận vai trò định vị đối tượng, còn CNN thực hiện phân loại cuối cùng trên vùng ảnh đã được cắt. Việc triển khai song song hai pipeline cho phép đánh giá sự đánh đổi giữa tốc độ xử lý và khả năng nhận dạng chi tiết đối với các lớp biển báo có đặc điểm tương đồng.




Ở giai đoạn triển khai, hệ thống cung cấp các giao diện suy luận độc lập cho từng pipeline và một cơ chế benchmark dùng để so sánh kết quả giữa các mô hình. Thiết kế này không chỉ phục vụ mục đích nghiên cứu mà còn tạo tiền đề cho việc tích hợp vào các ứng dụng giao thông thông minh hoặc hệ thống hỗ trợ lái xe trong tương lai.

3.3.2. Pipeline 1: YOLO End-to-End

Pipeline 1 được xây dựng theo hướng end-to-end, trong đó toàn bộ quá trình phát hiện và phân loại biển báo được thực hiện bởi một mô hình YOLO duy nhất. Đây là hướng tiếp cận thuộc nhóm single-stage detector, cho phép mô hình đồng thời dự đoán vị trí đối tượng và nhãn lớp trong một lần truyền dữ liệu qua mạng [10], [11].

Trong giai đoạn suy luận, ảnh đầu vào được đưa trực tiếp vào mô hình YOLO. Sau khi trích xuất đặc trưng thông qua backbone và các tầng hợp nhất đặc trưng, mô hình dự đoán các bounding box, xác suất lớp và giá trị confidence tương ứng. Các dự đoán sau đó được xử lý bằng Non-Maximum Suppression nhằm loại bỏ các bounding box chồng lấn và giữ lại những kết quả có độ tin cậy cao nhất [10], [14].



Trong kiến trúc này, cùng một mô hình chịu trách nhiệm cho cả hai nhiệm vụ localization và classification. Điều đó giúp giảm độ phức tạp của hệ thống, hạn chế chi phí truyền dữ liệu giữa các mô-đun và tối ưu tốc độ suy luận. Đây là một ưu điểm quan trọng đối với các ứng dụng yêu cầu xử lý thời gian thực như camera giao thông, hệ thống giám sát giao lộ hoặc các nền tảng hỗ trợ lái xe nâng cao [12]–[14].

Tuy nhiên, khả năng phân loại của mô hình phụ thuộc hoàn toàn vào bộ đặc trưng được học trong quá trình huấn luyện detector. Khi số lượng lớp lớn hoặc tồn tại nhiều biển báo có hình dạng và màu sắc tương đồng, mô hình có thể gặp khó khăn trong việc phân biệt các chi tiết đặc trưng nhỏ. Hạn chế này thường xuất hiện rõ hơn đối với các biển báo có kích thước nhỏ hoặc xuất hiện ở khoảng cách xa trong ảnh đầu vào.

Trong phạm vi đề tài, các mô hình YOLOv5n, YOLOv8n và YOLOv11n được huấn luyện và đánh giá trên cùng bộ dữ liệu nhằm lựa chọn detector có hiệu năng tốt nhất


cho Pipeline 1. Các chỉ số được sử dụng bao gồm Precision, Recall, mAP@0.5, mAP@0.5:0.95, FPS, thời gian suy luận và kích thước mô hình.

3.3.3. Pipeline 2: YOLO kết hợp CNN

Khác với Pipeline 1, Pipeline 2 áp dụng kiến trúc hai giai đoạn, trong đó nhiệm vụ phát hiện và nhiệm vụ phân loại được tách thành hai thành phần độc lập. Cách tiếp cận này tận dụng ưu thế của YOLO trong việc xác định vị trí đối tượng và khả năng học đặc trưng chuyên sâu của các mạng CNN hiện đại [15]–[17].

Ở giai đoạn đầu tiên, ảnh đầu vào được xử lý bởi mô hình YOLO để phát hiện vị trí các biển báo xuất hiện trong khung hình. Kết quả của bước này bao gồm các bounding box và độ tin cậy tương ứng. Thay vì sử dụng trực tiếp nhãn lớp từ YOLO, hệ thống chỉ khai thác thông tin vị trí đối tượng.

Sau khi xác định được vùng chứa biển báo, ảnh sẽ được cắt theo tọa độ bounding box và chuẩn hóa kích thước trước khi đưa vào bộ phân loại CNN. Trong nghiên cứu này, hai kiến trúc được lựa chọn để đánh giá là ResNet50 và EfficientNet-B0. Các mô hình được huấn luyện trên tập dữ liệu classification được xây dựng từ các ảnh crop thu được trong quá trình tiền xử lý dữ liệu.



Việc tách biệt hai nhiệm vụ mang lại một số lợi thế đáng kể. Bộ phân loại CNN được huấn luyện trực tiếp trên ảnh biển báo đã được cắt khỏi bối cảnh xung quanh, nhờ đó có thể tập trung học các đặc trưng hình học, màu sắc và ký hiệu đặc thù của từng lớp biển báo. Điều này đặc biệt hữu ích khi xử lý các lớp có mức độ tương đồng cao hoặc các biển báo chỉ khác nhau ở một số chi tiết nhỏ.

Đổi lại, Pipeline 2 phát sinh thêm chi phí tính toán do phải thực hiện hai lần suy luận liên tiếp. Ngoài thời gian xử lý của YOLO, hệ thống còn cần thực hiện bước cắt ảnh và phân loại bằng CNN. Vì vậy, tốc độ suy luận thường thấp hơn so với mô hình end-to-end, đặc biệt khi số lượng đối tượng xuất hiện trong ảnh lớn.

Trong nghiên cứu này, Pipeline 2 được xây dựng nhằm đánh giá liệu việc bổ sung một bộ phân loại chuyên biệt có giúp cải thiện chất lượng nhận dạng biển báo hay không. Kết quả thực nghiệm sẽ được sử dụng để so sánh trực tiếp với Pipeline 1 trên các tiêu chí về độ chính xác, tốc độ xử lý, kích thước mô hình và khả năng triển khai thực tế.

3.4. Xây dựng mô hình YOLO

3.4.1. Các mô hình YOLO sử dụng

Nhằm đánh giá khả năng ứng dụng của các phiên bản YOLO hiện đại đối với bài toán nhận diện biển báo giao thông Việt Nam, ba mô hình thuộc nhóm nano gồm YOLOv5n, YOLOv8n và YOLOv11n đã được lựa chọn. Đây đều là các biến thể được thiết kế theo hướng giảm số lượng tham số và tối ưu tốc độ suy luận, phù hợp với các hệ thống yêu cầu xử lý thời gian thực.

YOLOv5n là phiên bản nhẹ nhất trong họ YOLOv5. Kiến trúc của mô hình vẫn duy trì cấu trúc cơ bản gồm ba thành phần chính là Backbone, Neck và Detection Head.. Nhờ số lượng tham số thấp, YOLOv5n có tốc độ suy luận nhanh và yêu cầu tài nguyên phần cứng không quá cao.

YOLOv8n là biến thể nano của họ YOLOv8 do Ultralytics phát triển. So với các phiên bản trước, YOLOv8 được cải tiến theo hướng đơn giản hóa kiến trúc và tối ưu quá trình huấn luyện. Một trong những thay đổi đáng chú ý là cơ chế dự đoán anchor-free, giúp giảm độ phức tạp trong quá trình tối ưu và nâng cao khả năng phát hiện đối tượng ở nhiều kích thước khác nhau [14]. Những đặc điểm này đặc biệt phù hợp với bài toán nhận diện biển báo giao thông, nơi các đối tượng thường xuất hiện với kích thước nhỏ và phân bố không đồng đều trong ảnh.


YOLOv11n là thế hệ YOLO mới hơn, tiếp tục kế thừa định hướng tối ưu hóa hiệu năng suy luận trên các thiết bị có tài nguyên hạn chế. Mô hình được thiết kế nhằm nâng cao khả năng học đặc trưng đa tỷ lệ và cải thiện hiệu quả phát hiện đối tượng trong khi vẫn duy trì tốc độ xử lý cao. Điều này giúp YOLOv11n trở thành một lựa chọn tiềm năng cho các ứng dụng yêu cầu triển khai thực tế.

Cả ba mô hình đều được huấn luyện theo phương pháp transfer learning thông qua các trọng số tiền huấn luyện. Việc sử dụng pretrained model giúp tận dụng các đặc trưng đã học từ các bộ dữ liệu lớn, từ đó rút ngắn thời gian hội tụ và nâng cao khả năng tổng quát hóa trên bộ dữ liệu biển báo giao thông Việt Nam.

3.4.2. Data Augmentation trong huấn luyện YOLO

Tăng cường dữ liệu (Data Augmentation) là một kỹ thuật quan trọng trong quá trình huấn luyện các mô hình học sâu nhằm cải thiện khả năng tổng quát hóa và giảm hiện tượng quá khớp. Đối với bài toán nhận diện biển báo giao thông, dữ liệu thu thập trong thực tế thường có sự đa dạng lớn về điều kiện ánh sáng, khoảng cách quan sát, góc chụp và môi trường xung quanh. Do đó, việc tăng cường dữ liệu giúp mô hình học được các đặc trưng ổn định hơn trước những biến đổi này [12], [14].

Kỹ thuật tăng cường dữ liệu được nghiên cứu và đánh giá là Mosaic Augmentation. Đây là phương pháp ghép bốn ảnh huấn luyện khác nhau thành một ảnh mới, đồng thời điều chỉnh lại vị trí và nhân của các đối tượng tương ứng. Quá trình này tạo ra những mẫu dữ liệu đa dạng hơn so với dữ liệu gốc mà không cần thu thập thêm ảnh mới.



Khi áp dụng Mosaic, đối tượng có thể xuất hiện ở nhiều vị trí và tỷ lệ khác nhau trong cùng một ảnh huấn luyện. Điều này giúp mô hình học được khả năng phát hiện đối tượng ở nhiều kích thước khác nhau, đặc biệt là các đối tượng nhỏ. Đối với bài toán biển báo giao thông, lợi ích này có ý nghĩa quan trọng vì biển báo thường chỉ chiếm một vùng nhỏ trong ảnh và có thể xuất hiện ở nhiều khoảng cách quan sát khác nhau.


Bên cạnh việc làm tăng tính đa dạng của dữ liệu, Mosaic còn giúp mô hình tiếp xúc với nhiều bối cảnh khác nhau trong mỗi lần cập nhật trọng số. Nhờ đó, khả năng tổng quát hóa của mô hình được cải thiện và hiện tượng phụ thuộc quá mức vào một số mẫu dữ liệu cụ thể được giảm thiểu.

Trong quá trình thực nghiệm, đề tài tiến hành khảo sát cả hai trường hợp có và không sử dụng Mosaic nhằm đánh giá ảnh hưởng của kỹ thuật này đến hiệu quả huấn luyện.

3.4.3. Cấu hình huấn luyện YOLO

Quá trình huấn luyện YOLO được thực hiện trên bộ dữ liệu gồm 52 lớp biển báo giao thông Việt Nam đã được chuẩn hóa theo định dạng YOLO. Dữ liệu được chia thành hai tập riêng biệt gồm tập huấn luyện và tập xác thực nhằm phục vụ quá trình học và đánh giá mô hình.

Để đảm bảo tính nhất quán trong quá trình benchmark, các mô hình YOLO được huấn luyện theo cùng một quy trình. Trước tiên, mô hình được khởi tạo từ các trọng số tiền huấn luyện. Sau đó, dữ liệu huấn luyện được đưa vào mạng để thực hiện quá trình tối ưu hóa tham số. Sau mỗi epoch, mô hình được đánh giá trên tập xác thực nhằm theo dõi khả năng hội tụ và lựa chọn trọng số tốt nhất.



Trong nghiên cứu này, số epoch được cố định ở mức 100 cho tất cả các mô hình nhằm tạo điều kiện cho quá trình hội tụ diễn ra đầy đủ. Đồng thời, cơ chế Early Stopping được sử dụng để tự động dừng huấn luyện khi kết quả trên tập xác thực không còn cải thiện sau một số epoch nhất định, qua đó hạn chế hiện tượng quá khớp và giảm thời gian huấn luyện không cần thiết.

Bên cạnh việc so sánh các kiến trúc YOLO, đề tài còn khảo sát ảnh hưởng của một số siêu tham số quan trọng đến hiệu năng mô hình. Các tham số được lựa chọn dựa trên những yếu tố có ảnh hưởng trực tiếp đến chất lượng phát hiện đối tượng và chi phí tính toán.

Đối tượng khảo sát	Giá trị khảo sát
Model Yolo	Yolov5n, Yolov8n, Yolov11n
Epoch	100
Image Size	416, 640, 800

Đối tượng khảo sát	Giá trị khảo sát
Model Yolo	Yolov5n, Yolov8n, Yolov11n
Learning Rate	0.001, 0.005, 0.01
Batch Size	8, 16, 32
Mosaic	0, 1

Trong đó, kích thước ảnh đầu vào ảnh hưởng trực tiếp đến khả năng phát hiện các đối tượng nhỏ. Learning rate quyết định tốc độ cập nhật trọng số trong quá trình tối ưu hóa. Batch size tác động đến mức độ ổn định của quá trình học cũng như khả năng khai thác tài nguyên phần cứng. Đối với Mosaic, đây là tham số được sử dụng để đánh giá vai trò của tăng cường dữ liệu đối với hiệu năng của mô hình.

3.5. Xây dựng mô hình CNN

3.5.1. ResNet50

Trong nghiên cứu này, ResNet50 được sử dụng dưới dạng mô hình tiền huấn luyện trên ImageNet. Lớp Fully Connected cuối cùng của mạng được thay thế bằng một lớp phân loại mới có 52 đầu ra tương ứng với 52 lớp biển báo giao thông Việt Nam. Việc thay đổi lớp đầu ra giúp mô hình thích nghi với bài toán phân loại cụ thể của đề tài.

Bên cạnh đó, nghiên cứu áp dụng phương pháp Transfer Learning để tận dụng các đặc trưng đã học từ tập dữ liệu ImageNet. Trong quá trình huấn luyện, mô hình có thể được sử dụng theo hai chiến lược khác nhau gồm đóng băng phần backbone và chỉ huấn luyện lớp phân loại cuối hoặc tinh chỉnh toàn bộ mạng. Cách tiếp cận này cho phép đánh giá khả năng thích nghi của ResNet50 đối với dữ liệu biển báo giao thông Việt Nam.

3.5.2. EfficientNet-B0

Việc lựa chọn EfficientNet-B0 xuất phát từ đặc điểm cân bằng giữa độ chính xác và hiệu quả tài nguyên. So với các mạng CNN có độ sâu lớn, EfficientNet-B0 thường đạt hiệu năng tương đương hoặc cao hơn trong khi yêu cầu bộ nhớ và thời gian suy luận thấp hơn. Điều này đặc biệt quan trọng đối với các hệ thống nhận diện biển báo giao thông cần triển khai trên các thiết bị có giới hạn về tài nguyên phần cứng.


Trong phạm vi đề tài, EfficientNet-B0 được sử dụng như đại diện cho nhóm kiến trúc CNN hiện đại hướng đến tối ưu hiệu quả tính toán. Kết quả thực nghiệm sẽ được sử dụng

để so sánh với ResNet50 nhằm đánh giá mức độ phù hợp của từng kiến trúc đối với bài toán phân loại biển báo giao thông Việt Nam.

3.5.3. Cấu hình huấn luyện

Dữ liệu huấn luyện của CNN được xây dựng từ các ảnh biển báo đã được cắt theo thông tin bounding box của bộ dữ liệu gốc. Mỗi ảnh crop được gán nhãn tương ứng với lớp biển báo và được tổ chức theo cấu trúc thư mục phù hợp với cơ chế ImageFolder của PyTorch.

Quá trình huấn luyện được thực hiện theo quy trình gồm các bước: xây dựng tập dữ liệu, áp dụng các phép biến đổi ảnh, khởi tạo mô hình tiền huấn luyện, thực hiện Transfer Learning và tối ưu hóa các tham số của mạng.



Các mô hình được huấn luyện bằng thuật toán tối ưu Adam kết hợp với hàm mất mát Cross-Entropy Loss. Đây là lựa chọn phổ biến đối với các bài toán phân loại đa lớp nhờ khả năng hội tụ nhanh và ổn định. Đồng thời, kỹ thuật Early Stopping được áp dụng nhằm tự động dừng quá trình huấn luyện khi chất lượng trên tập xác thực không còn cải thiện trong một số epoch liên tiếp, từ đó hạn chế hiện tượng quá khớp.

Để đánh giá ảnh hưởng của các yếu tố huấn luyện đến chất lượng phân loại, nghiên cứu tiến hành khảo sát một số siêu tham số quan trọng gồm learning rate và chiến lược Transfer Learning. Learning rate được đánh giá ở nhiều mức khác nhau nhằm xác định tốc độ cập nhật trọng số phù hợp. Bên cạnh đó, hai chiến lược huấn luyện gồm đóng băng

backbone và tinh chỉnh toàn bộ mạng cũng được xem xét để đánh giá khả năng thích nghi của các mô hình đối với bộ dữ liệu biến báo giao thông.

Đối tượng khảo sát	Giá trị khảo sát
Model CNN	ResNet50, EfficientNet-B0
Learning Rate	0,0001; 0,001; 0,01
Transfer Learning Strategy	Frozen Backbone, Fine-tuning


Các mô hình sau khi huấn luyện được đánh giá thông qua các chỉ số Accuracy, Precision, Recall, F1-score, thời gian suy luận và kích thước mô hình. Trong đó, F1-score được lựa chọn làm tiêu chí chính để so sánh và lựa chọn mô hình do chỉ số này phản ánh đồng thời khả năng dự đoán chính xác và khả năng bao phủ đầy đủ các lớp dữ liệu [19].

CHƯƠNG 4: THỰC NGHIỆM VÀ KẾT QUẢ

4.1. Môi trường và kịch bản thực nghiệm

Quá trình thực nghiệm được tổ chức thành ba giai đoạn chính. Giai đoạn thứ nhất tập trung đánh giá các mô hình YOLOv5n, YOLOv8n và YOLOv11n nhằm lựa chọn mô hình phát hiện đối tượng phù hợp nhất cho bài toán nhận diện biển báo giao thông. Các mô hình được huấn luyện theo cùng một quy trình với số epoch cố định, đồng thời được đánh giá thông qua các chỉ số Precision, Recall, mAP@0.5, mAP@0.5:0.95, FPS, thời gian suy luận và kích thước mô hình. Sau khi xác định được mô hình có hiệu năng tốt nhất, nghiên cứu tiếp tục khảo sát ảnh hưởng của các siêu tham số như kích thước ảnh đầu vào, learning rate, batch size và kỹ thuật Mosaic Augmentation nhằm xác định cấu hình huấn luyện tối ưu.

Giai đoạn thứ hai được thực hiện trên tập dữ liệu phân loại ảnh đã được tạo từ các vùng crop biển báo. Hai kiến trúc CNN gồm ResNet50 và EfficientNet-B0 được huấn luyện bằng phương pháp Transfer Learning để đánh giá khả năng nhận dạng các lớp biển báo giao thông. Các mô hình được so sánh dựa trên Accuracy, Precision, Recall, F1-score, thời gian suy luận và kích thước mô hình. Song song với việc đánh giá kiến trúc mạng, nghiên cứu cũng khảo sát ảnh hưởng của learning rate và chiến lược huấn luyện, bao gồm đóng băng backbone và fine-tuning toàn bộ mạng, nhằm xác định cấu hình mang lại hiệu quả cao nhất.



Giai đoạn cuối cùng tập trung đánh giá hiệu năng của hai pipeline nhận diện biển báo. Pipeline thứ nhất sử dụng mô hình YOLO theo hướng end-to-end, trong khi Pipeline thứ hai kết hợp bộ phát hiện YOLO với bộ phân loại CNN. Việc so sánh được thực hiện trên các tiêu chí về độ chính xác nhận dạng, khả năng phát hiện đối tượng, tốc độ suy luận, số khung hình xử lý trên giây và kích thước mô hình. Kịch bản này cho phép đánh giá sự đánh đổi giữa tốc độ xử lý và chất lượng nhận dạng, từ đó xác định hướng tiếp cận phù hợp hơn đối với các hệ thống nhận diện biển báo giao thông trong điều kiện triển khai thực tế.

Để đảm bảo tính khách quan, tất cả các mô hình trong cùng một nhóm được huấn luyện và đánh giá trên cùng tập dữ liệu, cùng phân cứng, sử dụng cùng phương pháp chia dữ liệu và cùng bộ chỉ số đánh giá. Kết quả thực nghiệm được ghi nhận dưới dạng số liệu định lượng kết hợp với phân tích trực quan thông qua các biểu đồ huấn luyện, ma trận nhầm lẫn và kết quả suy luận trên ảnh thực tế. Cách tiếp cận này giúp đánh giá toàn diện cả về hiệu năng thống kê lẫn khả năng ứng dụng của hệ thống trong các tình huống giao thông thực tế.

4.2. Kết quả thực nghiệm YOLO

4.2.1. So sánh các mô hình YOLO

4.2.2. Phân tích ảnh hưởng Hyperparameter

4.2.3. Lựa chọn mô hình YOLO tốt nhất

4.3. Kết quả thực nghiệm CNN

4.3.1. So sánh ResNet50 và EfficientNet-B0

4.3.2. Phân tích Hyperparameter

4.3.3. Lựa chọn mô hình CNN tốt nhất

4.4. Đánh giá hai Pipeline

4.4.1. Pipeline YOLO End-to-End

4.4.2. Pipeline YOLO kết hợp CNN

4.4.3. So sánh và thảo luận

4.5. Triển khai hệ thống Web

4.5.1. Kiến trúc hệ thống

4.5.2. Giao diện người dùng

4.5.3. Kết quả kiểm thử

KẾT LUẬN VÀ KIẾN NGHỊ

1. Kết luận
2. Hạn chế
3. Kiến nghị

TÀI LIỆU THAM KHẢO

- [1] R. Szeliski, Computer Vision: Algorithms and Applications, 2nd ed. Cham, Switzerland: Springer, 2022.
- [2] D. A. Forsyth and J. Ponce, Computer Vision: A Modern Approach, 2nd ed. Upper Saddle River, NJ, USA: Pearson, 2011.
- [3] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA, USA: MIT Press, 2016.
- [4] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015.
- [5] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, “Gradient-based learning applied to document recognition,” *Proc. IEEE*, vol. 86, no. 11, pp. 2278–2324, Nov. 1998.
- [6] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Lake Tahoe, NV, USA, 2012, pp. 1097–1105.
- [7] R. Girshick, “Fast R-CNN,” in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, Santiago, Chile, 2015, pp. 1440–1448.
- [8] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 39, no. 6, pp. 1137–1149, Jun. 2017.
- [9] W. Liu et al., “SSD: Single shot multibox detector,” in *Proc. Eur. Conf. Comput. Vis. (ECCV)*, Amsterdam, The Netherlands, 2016, pp. 21–37.
- [10] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, real-time object detection,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, Las Vegas, NV, USA, 2016, pp. 779–788.

- [11] J. Redmon and A. Farhadi, “YOLO9000: Better, faster, stronger,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Honolulu, HI, USA, 2017, pp. 7263–7271.
- [12] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal speed and accuracy of object detection,” arXiv:2004.10934, Apr. 2020.
- [13] C.-Y. Wang, A. Bochkovskiy, and H.-Y. M. Liao, “YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Vancouver, BC, Canada, 2023, pp. 7464–7475.
- [14] G. Jocher et al., Ultralytics YOLO Documentation, 2023. [Online]. Available: <https://docs.ultralytics.com/>. [Accessed: Jun. 8, 2026].
- [15] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Las Vegas, NV, USA, 2016, pp. 770–778.
- [16] M. Tan and Q. V. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in Proc. 36th Int. Conf. Mach. Learn. (ICML), Long Beach, CA, USA, 2019, pp. 6105–6114.
- [17] M. Tan and Q. V. Le, “EfficientNetV2: Smaller models and faster training,” in Proc. 38th Int. Conf. Mach. Learn. (ICML), Virtual Event, 2021, pp. 10096–10106.
- [18] T. Fawcett, “An introduction to ROC analysis,” Pattern Recognit. Lett., vol. 27, no. 8, pp. 861–874, Jun. 2006.
- [19] D. M. W. Powers, “Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation,” J. Mach. Learn. Technol., vol. 2, no. 1, pp. 37–63, 2011.

[20] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The Pascal Visual Object Classes (VOC) challenge,” *Int. J. Comput. Vis.*, vol. 88, no. 2, pp. 303–338, Jun. 2010.